

**Caracterización de plantaciones forestales a partir de información
derivada de plataformas satelitales y servicios de procesamiento de
datos en la nube.**

*Trabajo final presentado para optar al título de
Especialista en Teledetección y Sistemas de Información Geográfica aplicados al
estudio de los recursos naturales y la producción agropecuaria*

Matías Carlos Gaute

Ingeniero Agrónomo- Universidad de Buenos Aires - 2008

Lugar de trabajo: Dirección de Producción Foresto Industrial. Ministerio de Agricultura
Ganadería y Pesca de la Nación Argentina.



Escuela para Graduados Ing. Agr. Alberto Soriano
Facultad de Agronomía - Universidad de Buenos Aires



TUTOR

Tutor

Walter Sione

Ingeniero Agrónomo Universidad Nacional de Entre Ríos.
Especialista en Teledetección, SIG y Cartografía Temática. Universidad de Alcalá de
Henares
Doctor en Ciencias Aplicadas, Universidad Nacional de Luján.

JURADO DE TRABAJO FINAL

Jurado

Marcos Texeira

Licenciado en Ciencias Biológicas
Facultad de Ciencias, Universidad de la República Oriental del Uruguay.
Doctor en Ciencias Agropecuarias (EPG, Facultad de Agronomía, UBA, Argentina).

Jurado

Gervasio Piñeiro Guerra

Ingeniero Agrónomo.
Facultad de Agronomía, Universidad de la República Oriental del Uruguay.
Doctor en Ciencias Agropecuarias (EPG, Facultad de Agronomía, UBA, Argentina).

Fecha de defensa del Trabajo Final: 7 de abril de 2021

Agradecimientos

A la EPG y los docentes de la carrera. A todos los técnicos que me aportaron su experiencia, sugerencias, consejos, en especial a Hugo, Teresa, Ernesto, Walter. A Julieta por su incansable aliento. A mis compañeros de trabajo.

A mi familia y especialmente a mis abuelos Celia y Carlos.

“Declaro que el material incluido en esta tesis es, a mi mejor saber y entender, original producto de mi propio trabajo (salvo en la medida en que se identifique explícitamente las contribuciones de otros), y que este material no lo he presentado, en forma parcial o total, como una tesis en ésta u otra institución”.

Tabla de contenido

Título:	1
Resumen	1
Abstract	1
1. Introducción	3
2. Objetivo general :	7
2.1. Objetivo específico	7
2.1.1. Estimación de variables de estado de plantaciones comerciales.	7
2.1.2. Análisis de alturas estimadas	7
3. Materiales y Métodos	7
3.1. Área de Estudio:	7
3.2. Datos de terreno	8
3.3. Información espectral	9
3.3.1.1. Sensores pasivos:	9
3.3.1.2. Sensores activos:	10
3.4. Procesamiento satelital	12
3.5. Análisis estadístico	13
3.5.1.1.1. Correlación entre datos de terreno y bandas espectrales.	13
3.5.1.1.2. Construcción de modelo de regresión lineal	13
3.6. Ajuste de modelo Altura dominante	14
3.7. Validación	15
3.8. Mapeo de variables estimadas	16
4. Resultados y Discusión	16
4.1. Modelos de regresión	16
4.2. Relación entre altura dominante HD, altura de canopeo y edad de la plantación.	24
4.3. Mapeo de las variables estimadas.	26
5. Conclusiones	28
6. Referencias bibliográficas	29

ÍNDICE DE FIGURAS

Figura 1. (A) Delimitación del área de estudio y detalle de la cartografía forestal elaborada sobre el departamento Concordia. (B) Distribución de parcelas de medición correspondientes al Inventario Nacional de Plantaciones Forestales durante 2015-2016.	8
Figura 2. Flujo del procesamiento de los datos.	13
Figura 3. Distribución de transectas correspondientes al producto ATL08 (ICESat-2) con datos altimétricos.	15
Figura 4. Gráficos de dispersión de los valores observados versus los estimados para la variable área basal (G) en m ² /ha.....	19
Figura 5. Gráficos de dispersión de los valores observados versus los estimados. (Vcc) [m ³ /ha].	20
Figura 6. Gráficos de dispersión de los valores observados de altura dominante (HD) [m] versus los estimados por el modelo (HD) [m]......	22
Figura 7. Índice de densidad (DR) Observado vs. Estimado.	23
Figura 8. Relación entre altura dominante (HD) estimada con modelo para el período (noviembre – diciembre 2019) y altura de canopeo relevada por ICESat- 2 (ATL08) (2019).	25
Figura 9 . Relación entre la altura de canopeo ICESat–2, altura de canopeo y edad de plantaciones.	26
Figura 10. Mosaico correspondiente a la altura dominante (HD) estimada para el año 2019 sobre el área de estudio.....	27

ÍNDICE DE TABLAS

Tabla 1. Estadística descriptiva correspondiente a las variables calculadas a partir de las parcelas inventariadas a campo	9
Tabla 2. Índices de vegetación utilizados.	10
Tabla 3. Modelos de regresión de las variables de estado forestal estudiadas sobre plantaciones de Eucalyptus.	17
Tabla 4 . Coeficientes de los modelos de regresión de las variables de estado forestal estudiadas ,área basal, volumen con corteza, altura dominante y el índice de densidad relativa.....	17
Tabla 5. Volumen calculado en parcelas a campo (INPF) y volumen estimado...	21

ÍNDICE DE ECUACIONES

Ecuación 1. Índice de densidad DR.....	9
Ecuación 2. Error cuadrático medio (RMSE).....	15

VISOR WEB

App Google Earth Engine	27
--------------------------------------	----

Título:

Caracterización de plantaciones forestales a partir de información derivada de plataformas satelitales y servicios de procesamiento de datos en la nube.

Resumen

La región Mesopotámica Argentina concentra el 80 % de las plantaciones forestales del país. A partir de información relevada a campo y la provista por los satélites Sentinel – 2 MSI y Sentinel-1 SAR GRD, se generaron modelos de regresión lineal para estimar distintas variables de estado forestales (área basal, volumen con corteza, altura dominante, índice de densidad) que permiten caracterizar el recurso forestal correspondiente a plantaciones comerciales del género *Eucalyptus* en el departamento Concordia de la provincia de Entre Ríos. El procesamiento de las imágenes satelitales se realizó a partir de Google Earth Engine para favorecer la automatización. El modelo predictor de área basal tuvo un R^2 (ajustado) de 0,77 y un RMSE de 2,53 m²/ha, el volumen con corteza tuvo R^2 (ajustado) de 0,75 y RMSE de 62,1 m³/ha, la altura dominante presentó un R^2 (ajustado) de 0,66 y un RMSE 4,89 m. Se obtuvo una diferencia del 6 % considerando el volumen estimado a partir del modelo y el calculado sobre las mediciones del inventario a campo. El índice de densidad relativa, evidenció sobreestimación de la variable respuesta. La altura dominante estimada se correlacionó positivamente con la altura de canopeo relevada a partir del satélite ICESat- 2 (ATL08) y ambas se relacionaron en forma lógica con las edades de los rodales estudiados. Este estudio presenta resultados alentadores en la estimación de las variables de estado de rodales de *Eucalyptus* comerciales a partir de información correspondiente a sensores remotos, modelos de regresión lineal y el procesamiento a partir de la plataforma Google Earth Engine.

Palabras Claves

Plantaciones forestales, variables de estado, índices de densidad, Sentinel MSI, procesamiento en la nube, inventarios forestales.

Title

Characterization of forest plantations based on information derived from satellite platforms and high-performance computing resources

Abstract

The Mesopotamian region of Argentina concentrates 80% of the country's forest plantations. Information collected in the field was used and that provided by the Sentinel - 2 MSI and Sentinel-1 SAR GRD satellites, linear regression models

were generated to estimate different forest state variables (basal area, volume, dominant height, density index) that allow characterizing the forest resource corresponding to commercial plantations of the genus *Eucalyptus* in the Concordia department of the province of Entre Ríos. The processing of the satellite images was carried out using Google Earth Engine to favor automation. The basal area predictor model had a (R^2 ajustado 0,77 y RMSE 2,53 m²/ha) the volume with bark (adjusted R2) 0.75 and RMSE 62.1 m³ / ha) the dominant height (adjusted R2 0.66 and RMSE 4.89 m) the relative density index, evidenced an overestimation of the response variable. A difference of 6% was obtained considering the volume estimated from the model and the one calculated on the field inventory measurements. The estimated dominant height was positively correlated with the canopy height surveyed from the ICESat-2 satellite (ATL08) and both were logically related to the ages of the studied stands. This study reflects promising results in the estimation of key forest plantation variables from remote sensing information, linear regression models and data processing in the Google Earth Engine platform.

Keywords

Forest inventories, regression models, remote sensing, cloud storage.

1. Introducción

A mediados de la década del '90, en el ámbito de la Dirección de Producción Forestal (DPF) del Ministerio de Agricultura Ganadería y Pesca de la Nación Argentina se conforma el Área de Sistema de Información Geográfica (SIG) e Inventario Forestal cuyo objetivo principal fuera el de cartografiar y monitorear los rodales forestales en todo el territorio nacional, utilizando técnicas de teledetección y SIG. La incorporación progresiva de nuevas herramientas tecnológicas permitió gestionar eficazmente la operatoria de la ley 25.080 de Inversiones para Bosques Cultivados, generando la cartografía de las plantaciones forestales. Un rodal forestal se define como una unidad básica, donde el cultivo forestal es más o menos homogéneo en términos de edad, composición y condición de especies (Hibberd, 1991; Prodan *et al.*, 1997).

Una masa forestal puede ser caracterizada a partir de tres parámetros dasométricos: número de árboles por hectárea (N), el área basal (G) y la altura dominante (HD). Con estos parámetros y a partir de diversas ecuaciones alométricas desarrolladas para varias especies, es posible por ejemplo estimar variables como el volumen con corteza (V) (Maggio *et al.*, 2016; Birger, 2015). El área basal [m^2/ha] corresponde al área de sección horizontal del árbol medida a 1,30 m de altura desde el suelo, es decir la altura de pecho a la cual se mide el diámetro del fuste (DAP). El área basal se calcula sumando las áreas (m^2) basales de los árboles dentro de una superficie determinada. Respecto a la altura dominante, existen muchas definiciones en la literatura específica (Bengoa Martínez de Mandojana, 1999). Assman (1970) define a la altura dominante como la altura correspondiente al árbol que presenta la sección normal media de los 100 árboles más gruesos por hectárea, obtenida a partir de la curva alturas-diámetros. Andenmatten (2019) ha contribuido al estudio de los modelos de simulación de crecimiento empleando índices de densidad, como el índice de Densidad Relativa de Curtis (DR) y el Factor Altura (FH) muy útiles para diseñar tablas de producción, diagramas de manejo de la densidad y simular el crecimiento de los rodales forestales.

La relación que existe entre la edad y la altura en plantaciones comerciales es conocida. Se incrementa con el desarrollo del árbol (Gómez-Tejero *et al.*, 2009; Crechi *et al.*, 2011). Poder estimar esta variable (edad o año de plantación a través de información satelital, resulta muy importante considerando que la base de datos cartográfica de la Dirección de Producción Forestal presenta en algunos casos cierto grado de desactualización debido a las altas tasas de crecimientos, los turnos de rotación y manejos silvícolas no contemplados en el régimen de la promoción forestal (Ley 25.080). Por otra parte estimar el índice DR a partir de un modelo de regresión resultaría muy útil, siendo que este parámetro se relaciona con el área basal y el diámetro cuadrático medio y Andenmatten (1999), Andenmatten *et al.*, (2017), Andenmatten (2019) han descripto los despejes matemáticos para derivar el número de individuos (N) por hectárea y de esta forma estimar la densidad de árboles en la plantación. Actualmente el DAP, la altura de los árboles, el número de árboles y otros

parámetros dasométricos son colectados y calculados a partir inventarios forestales con métodos tradicionales costosos.

En el campo de la teledetección, históricamente la Dirección de Producción Forestal ha utilizado la técnica de la interpretación visual de imágenes satelitales. Esta técnica consiste en analizar determinados patrones presentes en las imágenes para posteriormente digitalizar en forma manual los rodales. Se han empleado con el correr de los años distintas colecciones de imágenes satelitales, correspondientes a las plataformas Landsat 5/7/8, Spot 4/5/6/7, CBERS, fotografías aéreas y Sentinel. Sin embargo, existen muchas experiencias donde se utiliza la información espectral para estimar, cuantificar las variables de estado estructurales de los bosques (Kangas *et al.*, 2018), así como para identificar especies forestales y analizar la evolución a través del tiempo (Trends.Earth, 2018; Kennedy *et al.*, 2018), información muy valiosa a la hora de caracterizar las masas forestales y la dinámica de acumulación de biomasa forestal aérea (AGB). La relación entre la información espectral y la estructura forestal de los bosques ha sido ampliamente estudiada. Lu *et al.*, (2004), Sivanpillai *et al.*, (2006) han desarrollado investigaciones para determinar como la biomasa forestal y la sombra asociada al dosel se relacionan con los parámetros estructurales.

Hall *et al.*, (1995) utilizando modelos geométricos y combinaciones lineales de las reflectancias ha cuantificado la fracción del dosel iluminada por el sol, así como la sombras en bosques de Abeto negro (*Picea mariana*) en Minnesota; demostrando que la fracción de sombra aumenta con el aumento de la densidad de biomasa, el diámetro promedio a la altura del pecho, el índice de área foliar (LAI) y la productividad primaria neta aérea (NPP). Estudios preexistentes en *Eucalyptus* sugieren que a medida que los árboles envejecen y crecen en biomasa y altura, la cantidad y efectos de las sombras se modifican afectando la respuesta espectral. (Ponzoni *et al.*, 2015)

Muchos investigadores han empleado a la serie temporal Landsat para estimar la AGB, posiblemente debido a las características de las plataformas, la política de datos abiertos y gratuidad a partir de 2008 (Woodcock C.E *et al.*, 2008). Debido a su resolución espacial y temporal la serie Landsat ha sido utilizada exhaustivamente para el monitoreo forestal en relación a eventos naturales y antropogénicos desde el año 1972 (H. Nguyen *et al.*, 2020).

Ahl *et al.*, (2006), Urbazaev *et al.*, (2016) y Hansen *et al.*, (2013) han empleado estos recursos para caracterizar y cuantificar los cambios en los bosques a escala global, a partir de datos de la serie Landsat. Hall *et al.*, (2006) han correlacionando datos espectrales de imágenes Landsat con medidas de AGB obtenidas a partir de inventarios forestales. Hansen *et al.*, (2016) han utilizado esta plataforma para calibrar modelos sobre la base de datos Landsat OLI para estimar la altura de árboles en bosques de África Subsahariana.

En el caso de plantaciones comerciales dos Reis *et al.*, (2018) han experimentado derivando el área basal y el volumen V sobre rodales de *Eucalyptus*, también a partir de datos Landsat. Torres *et al.*, (2016) han trabajado estimando parámetros forestales en bosques de coníferas a partir de

las plataformas SPOT y QuickBird, encontrando buenas respuestas de los modelos de regresión ($R^2= 0,93$) en el caso de la variable altura total. Gebreslasie *et al.*, (2010) han estudiado la estructura forestal a partir de datos Aster, en plantaciones comerciales de *Eucalyptus* en el sur de KwaZulu Natal, Sudáfrica mejorando los resultados a partir de incorporación de otros índices (edad e índice de sitio) a los modelos construidos a partir de datos espectrales, alcanzando valores de $R^2=0,90$ en relación a la estimación de la altura, $R^2= 0,84$ el área basal y $R^2= 0,88$ en relación al volumen. Otros investigadores han evaluado similares parámetros a partir de información provista por radares de apertura sintética (SAR). (Ghasemi *et al.*, 2011). Actualmente las diferentes plataformas SAR integrando con imágenes ópticas y datos LIDAR están posibilitando la generación de mapas globales de la biomasa. (Fagua *et al.*, 2019).

Recientemente a partir del lanzamiento del satélite ICESat-2 el 15 de septiembre de 2018, se suma un nuevo instrumento para evaluar determinadas variables como la altura de canopy y otras variables de estado relacionadas con la estructura vertical y horizontal de las masas boscosas. Sobre todo la posibilidad de vincular mediciones locales con procesos globales. Narine *et al.*, (2019) han obtenido resultados alentadores en relación al mapeo del AGB mediante el empleo de datos obtenidos con ICESat-2 y Landsat 8OLI.

En el caso de la estimación del número de árboles por hectárea (densidad) Mohammadi *et al.*, (2010) han estimado la densidad en el norte de Irán mediante sensores remotos empleando Landsat 7 (ETM). Existen cada vez más, experiencias utilizando imágenes de alta resolución espacial (Beguet *et al.*, 2014) y LIDAR aerotransportados (Unger *et al.*, 2014). (Guillón *et al.*, 1988) estudiaron el desempeño de imágenes Landsat, en plantaciones de *Eucalyptus* de la provincia de Corrientes y evaluaron su capacidad de caracterización y cuantificación de las masas forestales, concluyendo que estas imágenes resultaron muy eficientes en la evaluación de rodales con un tamaño mínimo de 2 ha con precisiones en el orden del 90 %.

Nuevas herramientas aportarán nuevos datos permitiendo fortalecer los modelos. El uso de LIDAR aerotransportado está ampliamente utilizado en inventarios forestales en los países nórdicos desde el año 2007. Neuenschwander *et al.*, (2019) han obtenido ajustes entre la altura estimada con LIDAR satelital y LIDAR aerotransportado de $R^2 = 0,98$ y RMSE = 3,69 m.

En tanto que Watt *et al.*, (2015) estudiaron la predicción del índice de sitio a partir del empleo de LIDAR aerotransportado. Asimismo el 21 de enero de 2020 se publicaron los primeros datos de la misión Global Ecosystem Dynamics Investigation - GEDI (Qi *et al.*, 2019) otro LIDAR satelital de la NASA. Con lo cual, los datos de este tipo de instrumentos darán nuevas oportunidades para el desarrollo de modelos cada vez más robustos, mejorando los problemas conocidos de saturación en las estimaciones volumétricas a partir de imágenes satelitales. (Tang *et al.*, 2019). Por otra parte los datos SAR se integran con los ópticos. Pourshamsi *et al.*, (2018), han estudiado distintos métodos para poder fusionar datos LIDAR con datos PolINSAR, para poder realizar estimaciones de altura de dosel más robustas. Otra fuente de datos de interés son las del

satélite argentino SAOCOM 1a y 1b puestos recientemente en órbita. Desde el 27 de diciembre de 2019 están disponibles gratuitamente los datos de la misión ALOS PALSAR 2, (JAXA, 2019), que al igual que la plataforma argentina, cuentan con la banda polarimetría L (con mayor capacidad de penetración en el dosel y por lo tanto más adecuada para generar estudios interferométricos que permitan estimar la altura de la plantación). (Ghasemi *et al.*, 2011; de Abelleira *et al.*, 2013).

Los vehículos aéreos no tripulados (UAVs) están siendo utilizados cada vez más frecuentemente para capturar datos de estructura forestal, que permitan calibrar modelos, alcanzando precisiones en el mismo orden que los obtenidos con LIDAR (Thomas *et al.*, 2018; Bagaram *et al.*, 2018). Asimismo LIDAR aerotransportados sobre UAVs, podrían combinar las prestaciones de ambas tecnologías y ofrecer una herramienta de diagnóstico muy importante para el productor y los organismos vinculados con la gestión forestal (Dalla Corte *et al.*, 2020). Schumacher *et al.*, (2019), han evaluado estas tecnologías y la combinación con información espectral. Sin dudas inventarios a partir de múltiples recursos favorecería la frecuencia y cantidad de reportes relacionados con las existencias forestales. Astrup *et al.*, (2019), han descripto métodos de trabajos que incluyen la evaluación e implementación basados en este concepto.

Mediante nuevas metodologías basadas en la utilización de potentes servidores conectados entre sí a través de internet (“nube”) que paralelizan los geoprocesos, la disponibilidad de series completas de imágenes satelitales de distintas plataformas, sensores (activos, pasivos), fechas de adquisición actuales e históricas, es posible estudiar variables fenométricas muy útiles a la hora de obtener información complementaria para nutrir a la cartografía generada mediante los métodos tradicionales antes explicados.

Plataformas como Google Earth Engine (GEE) (Gorelick *et al.*, 2017) facilitan el acceso a grandes colecciones de datos espaciales y librerías para geoprocesamiento. Incluso cada vez surgen nuevas aplicaciones sobre la base de la utilización de esta plataforma (Gärtner, 2019; Canty *et al.*, 2019).

La plataforma GEE es muy adecuada para el procesamiento de grandes volúmenes de datos. Asimismo, los scripts generados son factibles de compartir con otros equipos de trabajo, promoviendo la interacción interdisciplinaria. Recientemente se han generado herramientas que permiten vincular el sistema de información geográfica QGIS (con la plataforma GEE con lo cual, es factible utilizar los productos generados y realizar múltiples geoprocesos combinando las particularidades de ambas herramientas. (gee-community, 2020). Otras plataformas como SEPAL (Open Foris, 2019), con similares características comienzan a tener relevancia por parte de las distintas agencias gubernamentales para múltiples propósitos. En tanto el software RStudio (RStudio Team, 2020) es ampliamente utilizado por la comunidad científica y su empleo para realizar análisis espaciales está presente en proyectos de común interés con los de la presente investigación. Actualmente hay disponibles paquetes de R específicos para poder realizar estimaciones de biomasa (Rejou-Mechain *et al.*, 2017) y también específicos para procesar

datos de inventarios forestales relevados con LIDAR aerotransportado, Package 'lidR' (Roussel *et al.*, 2018).

En este trabajo se abordó la aplicación de datos de sensores remotos en el entorno de procesamiento de la información geoespacial de Google Earth Engine, para la caracterización de plantaciones forestales en un área de la provincia de Entre Ríos. Se analizó también cómo estas técnicas pueden complementar a los métodos tradicionales de relevamiento.

2. Objetivo general

Emplear la información aportada por sensores remotos para caracterizar y cartografiar las plantaciones forestales, complementando los métodos tradicionales.

2.1. Objetivo específico

2.1.1. Estimación de variables de estado de plantaciones comerciales.

Evaluar la correlación entre las variables de estado forestales área basal [G (m^2/ha)], volumen con corteza [V_{cc} (m^3/ha)], altura dominante [HD (m)], índice de densidad (DR) y datos espectrales correspondientes al satélite Sentinel-2 MSI, Sentinel-1 SAR GRD, generando modelos de regresión lineal que permitan su estimación y posteriormente su mapeo.

2.1.2. Análisis de alturas estimadas

Estudiar el comportamiento de la altura dominante (HD) estimada con el modelo de regresión lineal y altura de canopeo relevada por ICESat-2. Poder iniciar evaluaciones con esta potente herramienta resulta fundamental, ya que permitirá incorporar otras fuentes de datos disponibles para validar y calibrar modelos. En este trabajo se evalúa la relación entre la altura de canopeo, la altura dominante (HD) y su relación con otra variable de interés forestal como es la edad de la plantación.

3. Materiales y Métodos

3.1. Área de Estudio:

El área de estudio corresponde al departamento Concordia de la Provincia de Entre Ríos. Según el último Inventario Nacional de Plantaciones Forestales – INPF, realizado en la provincia de Entre Ríos (INPF, 2017), la superficie implantada es de 13.360 ha de *Pinus* y 112.799 ha de *Eucalyptus*,

representando el 10% aproximadamente de la superficie forestada a nivel nacional. El departamento seleccionado, presenta 51.042 ha de *Eucalyptus*.

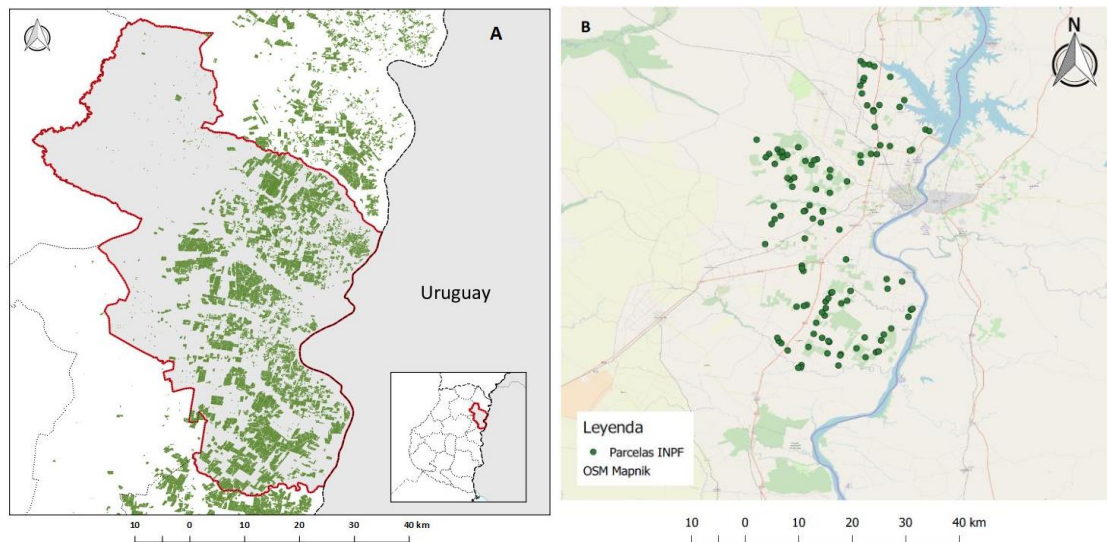


Figura 1. (A) Delimitación del área de estudio y detalle de la cartografía forestal elaborada sobre el departamento Concordia. (B) Distribución de parcelas de medición correspondientes al Inventario Nacional de Plantaciones Forestales durante 2015-2016. Mapa base correspondiente al proyecto Open Street Map - © OpenStreetMap contributors.

3.2. Datos de terreno

Durante los meses de febrero a mayo de 2016 en el marco del Inventario Nacional de Plantaciones Forestales (INPF) se realizaron muestreos y mediciones en el departamento Concordia de la Provincia de Entre Ríos. Se disponía de 105 parcelas relevadas a campo con información correspondiente al DAP [cm] medida con cinta diamétrica, altura total del fuste (H) [m] medida a partir de hipsómetro digital Haglöf Vertex IV sobre cada árbol dentro de la parcela. La altura promedio (HM) [m] calculada a partir del promedio de las alturas totales, el número de árboles por ha (N) [pl/ ha] la cual se obtuvo a partir de la suma de individuos contabilizados dentro de la parcela de medición de (500 m²). El volumen total con corteza (Vcc) [m³ /ha] fue estimado a partir de ecuaciones alométricas desarrolladas por Fassola *et al.*, (2007)

Por otra parte en cada parcela circular se calcularon el área basal G (m²/ha), la altura dominante HD [m] y el diámetro cuadrático medio Dg [cm] (el diámetro equivalente al árbol de área basal media), de acuerdo a la metodología descrita por Andenmatten *et al.*, (2013). El Índice de Densidad Relativa (DR) descrito por Andenmatten (1999, 2017 y 2019) siendo

Ecuación (1): **DR**: Densidad Relativa,

$$DR = G \times Dg^{-0.5}$$

Donde G : área basal (m^2/ha) y Dg : el diámetro cuadrático medio (cm); b : coeficiente propio de cada especie, siendo 0,5 un valor ampliamente utilizado (Andenmatten, 2017). En la tabla 1 se puede visualizar la estadística descriptiva de las variables de interés forestal calculadas a partir de los datos relevados a campo.

Tabla 1. Estadística descriptiva correspondiente a las variables calculadas a partir de las parcelas inventariadas a campo . Volumen con corteza (V_{cc}), Área basal (G), Diámetro medido a la altura del pecho (DAP), Diámetro cuadrático medio (Dg), Altura promedio (HM), Altura dominante (HD), Índice Densidad Relativa (DR).

Estadística descriptiva	V_{cc}	G	DAP	Dg	HM	HD	DR
Media	183,93	17,81	16,61	17,32	19,67	24,01	4.07
Mediana	186,19	18,9	16,96	17,7	20,49	24,48	0.15
Mínimo	10,31	2,18	8,05	8,19	8,43	10,17	1.37
Máximo	455,2	35,29	27,28	27,71	32,54	37,01	0.75
SD	103,63	7,05	3,93	4,04	5,36	6,88	6.52
CV	0,56	0,4	0,24	0,23	0,27	0,29	5.77

Referencias: V_{cc} : Volumen con corteza [m^3/ha], G : Área basal [m^2/ha], DAP : Diámetro medido a la altura del pecho (1,30 m) [cm], Dg : Diámetro cuadrático medio [cm], HM : Altura promedio [m], HD : Altura dominante [m], DR : Índice Densidad Relativa [sin unidad], Media, Mediana, Mínimo, Máximo, SD : Desvío estandar y CV : Coeficiente de variación .

3.3. Información espectral

A partir de la interfaz de programación de GEE se accedió a las imágenes satelitales que se describen a continuación:

3.3.1.1. Sensores pasivos:

3.3.1.1.1. Sentinel-2 MSI (2A / 2B) :

Se utilizó la información espectral correspondiente al sensor instrumento multiespectral (MSI) del satélite Sentinel-2 correspondiente a una de las misiones satelitales de la Agencia Espacial Europea (ESA) del programa Copernicus. El nivel de procesamiento utilizado fue L1C (valores de reflectancia TOA, tope de atmósfera), con una cobertura temporal de imágenes desde el 23/06/2015. El sensor presenta 13 bandas espectrales con distintas

resoluciones espaciales. La resolución radiométrica del instrumento MSI es de 12 bits, lo que permite que la imagen se adquiera en un rango de valores de intensidad de luz potencial de 0 a 4095.

Para este estudio de acuerdo a las investigaciones preexistentes en la bibliografía se seleccionaron las bandas (B2, B3, B4, B8) de 10 m de resolución espacial y las bandas (B5, B6, B7, B8A, B11, B12) de 20 metros. Asimismo a partir de estas bandas se generaron los siguientes índices espectrales, Índice de vegetación de diferencia normalizada (NDVI), Índice de Vegetación Ajustado al Suelo (SAVI), diferencia normalizada (ND54). (Tabla 2). Todos los índices han sido utilizados ampliamente con similares propósitos por muchos investigadores, los cuales han recurrido a múltiples plataformas como Landsat, Sentinel, Spot o CBERS entre otras. En el caso del Índice de Vegetación Ajustado al Suelo SAVI (Soil Adjusted Vegetation Index) tiene en cuenta la reflectividad del suelo sobre el valor del índice, para lo cual se incorpora un factor de corrección (L), que puede tomar valores entre 0 y 1, dependiendo de la densidad de la vegetación del sitio bajo estudio. En este caso se ha utilizado el valor (0,5) propuesto y utilizado por muchos otros investigadores (dos Reis et al., 2018). Con el tercer índice se evaluó el desempeño de la banda correspondiente al infrarrojo cercano de onda corta (SWIR). Los resultados de la investigación obtenidos a partir de estos índices permiten la comparación con otros preexistentes. (Lu et al., 2004).

Tabla 2. Índices de vegetación utilizados.

ÍNDICE	ECUACIÓN	FUENTE
NDVI	$(B8A-B04)/(B8A+B04)$	Adaptando el índice NDVI propuesto por Rouse et al., (1973).
ND54	$(B11-B8A)/(B11+B8A)$	Adaptando el índice ND54 propuesto por Huete et al., (2002).
SAVI	$(1.5*(B8A-B04)/(B8A+B04+0.5))$	Adaptando el índice SAVI propuesto por Huete et al., (1988).

Referencias: **NDVI:** Índice de vegetación de diferencia normalizada, **ND54:** Índice de vegetación de diferencia normalizada, **SAVI:** Índice de vegetación ajustado al suelo.

3.3.1.2. Sensores activos:

3.3.1.2.1. Sentinel -1 Ground Range Detected (GRD):

Fue lanzado al espacio el 3 abril de 2014 en el marco del programa Copernicus (ESA). Su instrumento principal es un radar de apertura sintética (SAR) en banda C (frecuencia central de 5.405 GHz) que opera en cuatro modos de adquisición. El instrumento C-SAR admite el funcionamiento de las

polarizaciones (en modo single y dual). Las combinaciones posibles son banda única VV o HH y banda dual VV + VH y HH + HV. ((ESA, 2020).

En este estudio se utilizaron imágenes de acuerdo a esta descripción:

- Nivel de procesamiento: Las imágenes accesibles a través de la API de GEE 'COPERNICUS/S1_GRD'Sentinel-1 ImageCollection corresponden a escenas de Nivel 1 detectado del rango de terreno (GRD) procesadas para coeficiente de retrodispersión (σ°) en decibelios (dB).
- Polarización: vertical, vertical - VV.
- Órbita: descendente.

- Modo de adquisición: franja interferométrica ancha (IW) es el modo de adquisición principal sobre tierra y satisface la mayoría de los requisitos de servicio. Adquiere datos con una franja de 250 km a una resolución espacial de 5 m por 20 m. El modo IW captura tres sub-franjas utilizando la observación de terreno con escaneos progresivos SAR (TOPSAR). Con la técnica TOPSAR, además de dirigir el haz en el rango, el haz también se dirige electrónicamente de atrás hacia adelante en la dirección azimutal para cada ráfaga, evitando el festoneado y dando como resultado una calidad de imagen homogénea en toda la franja (De Zan *et al.*, 2006).

3.3.1.2.2. ATL08 - ICESat-2

La misión ICESat-2 recopila datos de altimetría de la superficie de la Tierra. El único instrumento en ICESat-2 es el instrumento Advanced Topographic Laser Altimeter System (ATLAS) que mide el cambio de elevación de la capa de hielo y el espesor del hielo marino, al tiempo que genera una estimación de la biomasa de la vegetación global. ICESat-2 continúa con el relevamiento del cambio de elevación de la capa de hielo y la altura del dosel de vegetación iniciadas por ICESat en 2003 (Neuenschwander *et al.*, 2019). El conjunto de datos (ATL08) contiene alturas a lo largo de la pista por encima del elipsoide WGS84 (marco de referencia ITRF2014) para las superficies del suelo y del dosel. El dosel y las superficies del suelo se procesan en segmentos de datos fijos de 100 m, que generalmente contienen más de 100 fotones de señal. Los datos se descargaron del sitio web del Centro Nacional de Datos de Nieve y Hielo (NSIDC). <https://nsidc.org/data/atl08>

3.4. Procesamiento satelital

Se construyó un mosaico a partir de imágenes satelitales de la plataforma Sentinel-2 MSI, con umbral de nubosidad máxima de 5 %, correspondientes a los meses de febrero a mayo 2016, de forma tal de sincronizar espacial y temporalmente los datos espectrales con las mediciones dasométricas relevadas a campo durante el Inventario. Al generar el mosaico, se compilaron las bandas (B2 a B12), índices de vegetación (NDVI, ND54, SAVI) y variables transformadas (aplicando el logaritmo natural). GEE, posee algoritmos de agregación o reducción de datos, que permiten calcular para cada pixel del mosaico, el valor promedio de cada banda compilada, dentro del rango temporal establecido.

Se geolocalizaron 93 parcelas circulares de 500 m² correspondientes al inventario forestal y se extrajeron los valores espectrales de todos los pixeles del mosaico, circunscriptos a las parcelas. Finalmente se conformó un set de datos correspondiente a la información dasométrica de cada parcela y sus

correspondientes valores promedio de cada banda del mosaico (bandas espectrales, los índices de vegetación, las variables transformadas). Todo el proceso se programó en lenguaje JavaScript en el entorno de la interfaz de programación de GEE (Figura 2).

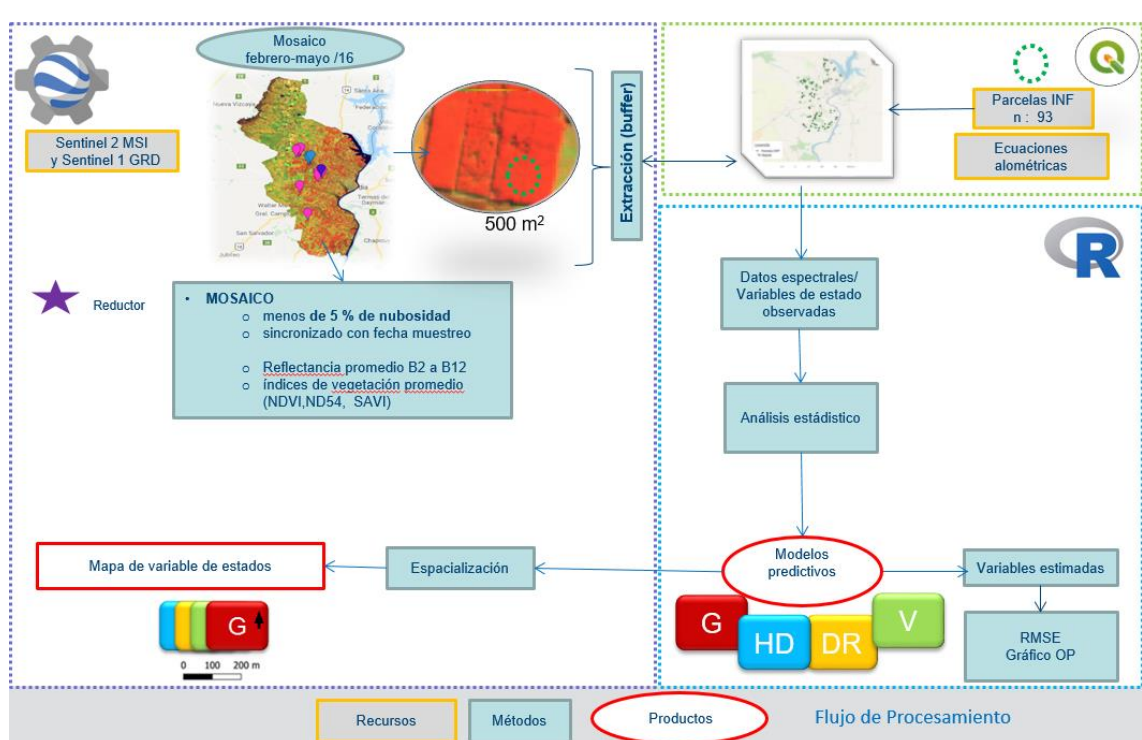


Figura 2. Flujo del procesamiento de los datos para la generación de modelos predictivos y mapas de las variables de estado estimadas.

3.5. Análisis estadístico

3.5.1.1.1. Correlación entre datos mediciones de terreno y bandas espectrales.

Se realizó un análisis de correlación a partir del coeficiente de correlación de Pearson (r) entre los datos espectrales (bandas espectrales, índices de vegetación (NDVI, ND54, SAVI) y variables transformadas (aplicando el logaritmo natural) y los datos de terreno para analizar en forma exploratoria que variables tenían mayor valor de coeficiente (r) identificando magnitud y sentido de esta relación.

3.5.1.1.2. Construcción de modelo de regresión lineal

Se utilizó el 75% de las parcelas para entrenar y generar los modelos y el 25 % de las parcelas para su correspondiente validación. Inicialmente se realizó un análisis para detectar outliers en los datos correspondientes a las mediciones

dasométricas. Mediante un análisis stepwise fueron generados y seleccionados los modelos de regresión múltiple privilegiando los que tuvieran mayor valor de coeficiente de determinación ajustado (R^2 ajustado) y el mínimo valor de Akaike (AIC) (Di Rienzo *et al.*, 2013; Vanclay, 1994) el cual brinda una medida de la calidad relativa entre los modelos evaluados. Se corroboraron los supuestos de normalidad a partir del test de Shapiro - Wilks (SW), de independencia a partir del test Durbin Watson (DW) y análisis visual de los residuales (Huang *et al.*, 2003). Asimismo para detectar posibles correlaciones entre variables explicativas (multicolinealidad), se utilizó el factor de inflación de la varianza (FIV) definiéndose el valor de corte en 10. Todo el procesamiento estadístico se efectuó con el software RStudio (RStudio Team, 2020).

3.6. Ajuste de modelo Altura dominante.

Se descargaron las transectas correspondientes a las órbitas del satélite ICESat-2 – ATL08 (2019) sobre el área de estudio (Figura 3). A partir de un geoproceso de intercepción, se seleccionaron los rodales muestreados a campo y que además contenían información altimétrica correspondiente a las transectas. Posteriormente a partir de otro geoprocésamiento (asignación de atributos por localización) se transfirieron los atributos de la cartografía de plantaciones forestales a cada punto con la información altimétrica del producto ATL08 - ICESat-2. Este proceso se realizó con el sistema de información geográfica QGIS versión Madeira (3.4.145 LTR). Luego se filtraron aquellos puntos con fecha de plantación posterior al 2005 para evitar errores en el análisis a causa de datos inconsistentes en la base de datos (plantaciones cosechadas con nuevas rotaciones y/o actualmente conducidas bajo manejo de rebrotes). Finalmente se obtuvo la altura de canopeo promedio de cada rodal seleccionado. Sobre los mismos rodales, a partir del modelo desarrollado para la estimación de altura dominante, se obtuvo la altura dominante promedio para el año 2019 configurando en el script desarrollado previamente en GEE la utilización de las fechas de imágenes Sentinel 2 correspondientes a noviembre y diciembre 2019. Finalmente se hizo un análisis comparativo entre la altura dominante promedio estimada con el modelo y la altura de canopeo promedio aportada por la plataforma ICESat-2.

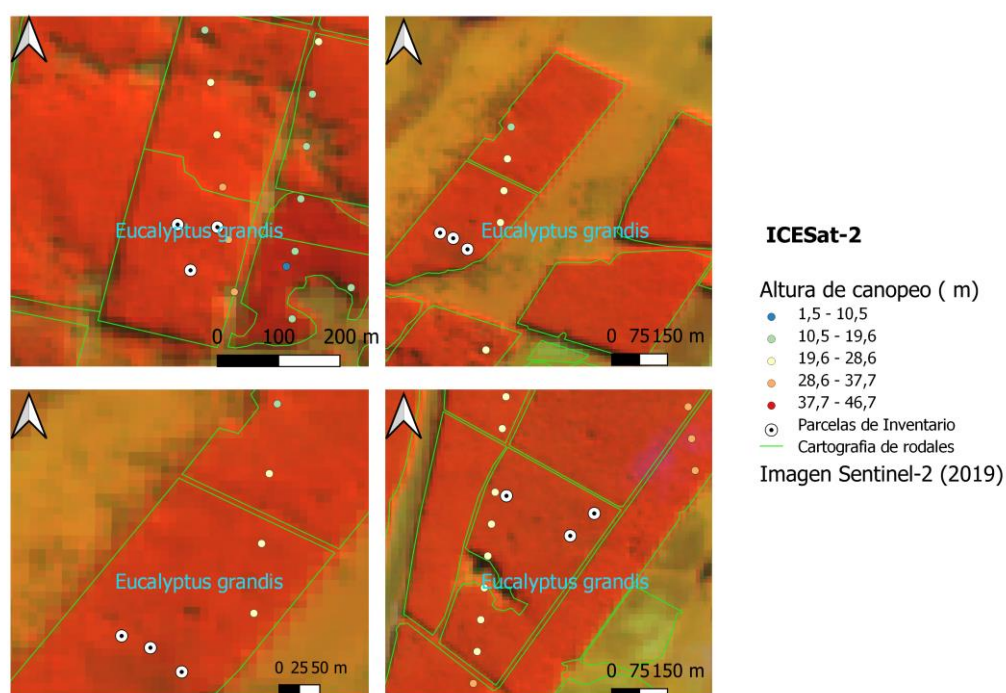


Figura 3. Distribución de transectas correspondientes al producto ATL08 (ICESat-2) con datos altimétricos. La imagen de fondo corresponde Sentinel-2 de abril de 2019. RGB: bandas infrarrojo cercano - NIR (B8), infrarrojo de onda corta SWIR (B11), rojo (B4) respectivamente. Se identifica la ubicación de parcelas relevadas a campo sobre la cartografía forestal, las cuales no coinciden espacialmente sobre las transectas de puntos relevados por el satélite ICESat-2.

3.7. Validación

Para la validación (evaluación de discrepancias entre valores observados y estimados) se calculó el error cuadrático medio (RMSE) a partir del 25 % de los datos correspondientes a las parcelas inventariadas, las cuales no fueron utilizadas para el entrenamiento de los modelos. De acuerdo a recomendaciones efectuadas Piñeiro *et al.*, (2008), se han generado gráficos para evaluar las regresiones lineales, proyectando la variable observada sobre el eje [y] y la predicha o estimada sobre el eje [x]. (OP).

Ecuación (2):

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (X_i - \hat{X}_i)^2}$$

Siendo:

N es el número de valores a evaluar, \hat{x}_i es el valor estimado,
y X_i es el valor observado.

En el caso de la variable volumen con corteza (Vcc), se analizó además el volumen total estimado con datos de campo (sumatoria del volumen medido en cada parcela, multiplicado por la superficie total relevada) respecto al volumen total estimado (sumatoria del volumen estimado de cada parcela por la superficie total relevada) calculándose la diferencia porcentual.

3.8. Mapeo de variables estimadas

Se incorporaron los modelos generados con RStudio, mediante la interfaz de programación de GEE, para las variables estudiadas y se obtuvo la información espacialmente explícita para el año 2016, en que se realizaron las mediciones a campo. En el caso de la variable altura dominante, también se generaron mapas con la altura estimada para el año 2019.

4. Resultados y Discusión

4.1. Modelos de regresión

Se obtuvieron 4 modelos de regresión con un buen ajuste (Tabla 3 y 4), para estimar las variables de estado forestales de interés para los géneros *Eucalyptus* a partir de datos espectrales. Todos los modelos seleccionados superaron los test cumpliendo con los supuestos estadísticos. Al igual que en otras investigaciones, las bandas correspondientes al infrarrojo fueron seleccionadas en el proceso análisis stepwise. Hall *et al.*, (2006); dos Reis *et al.*, (2018) seleccionaron para sus modelos las bandas 4 (0.775-0.90 μm) y 5 (1.55-1.75 μm) del satélite Landsat TM y ETM y respectivamente. En este estudio fueron seleccionadas las bandas de Sentinel-2 B8A (864.8nm) y B11 (1613.7nm) cuyas longitudes de onda se ubican dentro de los rangos citados al utilizar Landsat. El signo de las correlaciones, entre la información espectral y variables dasométricas, también fue positivo en el caso del índice NDVI y negativo en el caso del índice ND54, coincidiendo con lo reportado por otros investigadores (Hall *et al.*, 2006; dos Reis *et al.*, 2018). Gemmell *et al.*, (1995) determinaron que la 5 (infrarrojo cercano de onda corta) de Landsat TM estaba inversamente relacionada con el volumen de madera del rodal.

Tabla 3. Modelos de regresión de las variables de estado forestal estudiadas, área basal, volumen con corteza, altura dominante y el índice de densidad relativo, sobre plantaciones de Eucalyptus en el departamento Concordia, Entre Ríos.

Variables	MODELO	R2 Ajust	AIC	Shapiro-Wilks p-valor	Durbin Watson p-valor	r Pearson (OP)	RMSE
G	$\ln G = \ln(B8A) \cdot b1 + NDVI \cdot b2 + B11 \cdot b3 + b0$	0,77	9,27	0,908	0,814	0,86	2,53
V	$\ln V = \ln(B8A) \cdot b1 + NDVI \cdot b2 + B11 \cdot b3 + b0$	0,75	86,9	0,11	0,576	0,81	62,10
HD	$\ln HD = \ln(B8A) \cdot b1 + B11 \cdot b2 + \ln(SAVI) \cdot b3 + b0$	0,66	-42,02	0,123	0,578	0,81	4,89
DR	$\ln DR = \ln(B8A) \cdot b1 + NDVI \cdot b2 + B11 \cdot b3 + b0$	0,72	-2,65	0,1051	0,808	0,95	2,16

Referencias: Área basal (G) [m²/ha], Volumen con corteza (V) [m³/ha], Altura dominante (HD) [m], Índice de densidad relativo (DR). (B8A) y (B11) corresponden a la nomenclatura correspondiente las bandas (8A) infrarrojo cercano (NIR) y (11) infrarrojo cercano de onda corta (SWIR). (ln) corresponde al logaritmo natural. R² ajust. (Coeficiente de determinación ajustado), AIC (Criterio de Información de Akaike), r (Coeficiente de correlación de Pearson), RMSE (Error cuadrático Medio), p-valor (valor de probabilidad empleado correspondiente al test Shapiro Wilks y Durbin Watson).

Tabla 4. Coeficientes de los modelos de regresión de las variables de estado forestal estudiadas, área basal, volumen con corteza, altura dominante y el índice de densidad relativa, sobre plantaciones de Eucalyptus en el departamento Concordia, Entre Ríos.

Variable estado	b0	b1	b2	b3
G	-26,61	5,776	-17,026	-0,004
V	-40,84	9,23	-28,61	-0,0064
HD	-26,00	4,09	-0,0028	-9,485
DR	-23,85	5,017	-15,238	-0,003

Referencias: Área basal (G) [m²/ha], Volumen con corteza (V) [m³/ha], Altura dominante (HD) [m]. Índice de densidad relativo (DR).

Por otro lado, en nuestro trabajo las bandas del espectro visible fueron descartadas por los procesos de selección (stepwise). En esta porción del espectro electromagnético se evidencia mayor dispersión atmosférica y por lo tanto se ve afectada la correlación con las variables hipsométricas (dos Reis et al., 2018). De igual modo, en nuestro estudio las variables polarimétricas de Sentinel -1 fueron descartadas en el proceso de selección stepwise; sin embargo, Chen L. et al., (2019) han encontrado un buen desempeño de la información de esta plataforma para describir la textura espectral.

Respecto a los índices espectrales el NDVI fue seleccionado en los modelos para estimar el área basal, volumen con corteza y el índice de densidad. En tanto el índice espectral SAVI fue seleccionado en el modelo para la estimación de la altura dominante. La diferencia normalizada (ND54) no fue seleccionada en ninguno de los modelos, pero si las bandas que lo constituyen como se mencionó anteriormente.

Estudios futuros en la misma línea podrían considerar incluir en los análisis otros índices espectrales y también texturales tal como se propone también en Chen L. et al. (2019) y Lu et al., (2004).

Respecto al nivel de procesamiento de las imágenes Sentinel-2 empleadas correspondieron al nivel de procesamiento L1C. Debido a que al momento de realizar el procesamiento GEE disponía de este recurso. Desde el 27 de marzo de 2019, se disponibilizaron imágenes Sentinel-2 con nivel de procesamiento L2A (Gärtner, 2019), correspondientes a imágenes corregidas atmosféricamente a nivel del suelo (BOA, Bottom of the Atmosphere). Estas imágenes corresponden al período 28/03/2017 al presente. Es decir, son posteriores a la ejecución de las tareas de campo. Si bien era posible realizar este procesamiento a partir de software específico SEN2COR (Sen2Cor, 2020) el interés de este estudio fue evaluar el uso de la plataforma GEE, como se mencionó en la introducción. El uso de imágenes con esta corrección podría afectar los parámetros de los modelos por lo que sería apropiado evaluar el comportamiento de los algoritmos desarrollados en nuevas estimaciones, cambiando las imágenes configuradas inicialmente por las disponibles a la actualmente con el nivel de corrección (L2A).

En este estudio no se determinó cual es el rango de valores para cada variable analizada, a partir del cual se presentan comportamientos de saturación. Pero en próximos estudios será importante considerar las limitantes de estas estimaciones. Es conocido este tipo de comportamientos al estimar determinadas características biofísicas. Zhao et al., 2016 han reportado valores saturación de biomasa aérea en bosques de Pinus y Bosque mixtos de 159 y 152 Mg /ha, respectivamente) en el este de China, empleando imágenes Landsat 5 TM.

El modelo para la estimación del área basal (G) presentó mejor desempeño en las estimaciones (R^2 ajust. = 0,77) que los modelos empleados para la estimación de las restantes variables (Tabla 3). En relación al análisis de valores Observados versus Predichos los datos se correlacionaron lo cual se

evidencia en la distribución de puntos en el gráfico sobre la recta de ajuste (1:1) (Figura 4). El coeficiente de correlación de Pearson fue muy alto ($r = 0,86$) al igual que en el resto de las evaluaciones para las restantes variables. El RMSE fue de $2,53 \text{ m}^2/\text{ha}$, resultando muy alentador considerando los resultados citados en otras investigaciones (dos Reis *et al.*, 2018; Ponzoni *et al.*, 2012).

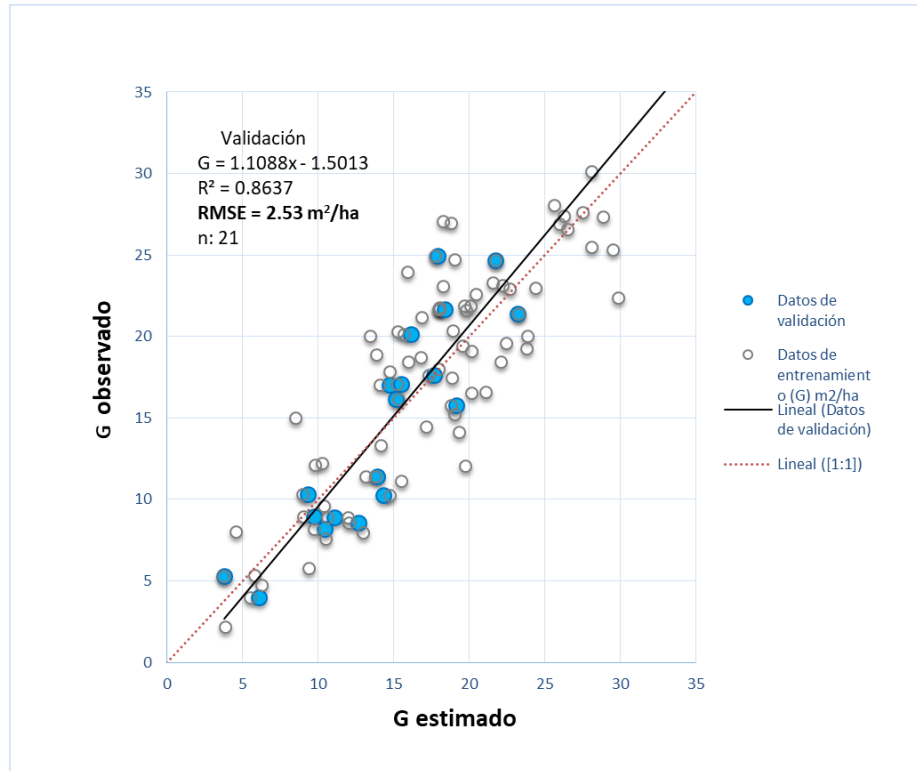


Figura 4. Gráficos de dispersión de los valores observados versus los estimados para la variable área basal (G) en m^2/ha . En línea roja se observa la recta de ajuste de referencia (1:1).

El modelo para la estimación del volumen con corteza, presentó un ajuste similar (R^2 ajust. = $0,75$), comparado con el de área basal. Resultados similares fueron informados por dos Reis *et al.*, (2018) y Ponzoni *et al.*, (2012) al estimar estas variables. Del análisis del gráfico Observados vs Predicho se observó mayor dispersión de los puntos, respecto a la recta de ajuste (1:1), a mayores valores de volúmenes con corteza (Figura 5). El RMSE fue de $(62,10 \text{ m}^3/\text{ha})$.

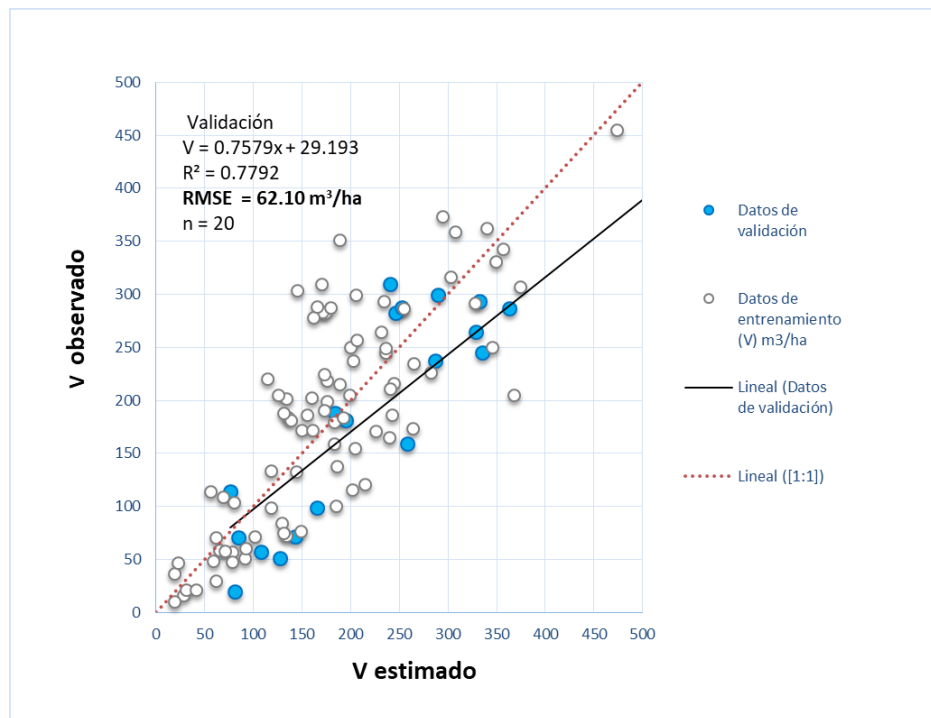


Figura 5. Gráficos de dispersión de los valores observados del volumen con corteza versus los estimados por el modelo en m^3/ha . En línea roja se observa la recta de ajuste de referencia (1:1).

Posiblemente el menor rendimiento predictivo del modelo de volumen con corteza puede deberse a la mayor dispersión presente en los valores utilizados en la fase de entrenamiento del modelo (Tabla 1) y la metodología para realizar el cálculo dasométrico de cada una de estas variables. Por un lado la determinación del volumen dentro cada parcela relavada a campo surge de ecuaciones alométricas, que no han sido calibradas para todos los sitios ni estratos de plantaciones de *Eucalyptus* y podrían introducir errores en los valores estimados; estos algoritmos emplean los datos de DAP, un coeficiente teórico correspondiente a la factor del fuste (coeficiente de forma) y los datos de altura de los árbol medidos. Contrariamente la variable área basal surge de la ecuación que contempla únicamente los datos de DAP, medidos a campo con una cinta directamente sobre el fuste de los árboles. (dos Reis *et al.*, 2018). Por otra parte la altura es una variable de mayor dificultad de medición a campo, en condiciones climáticas adversas (por ejemplo, viento), donde la correcta selección del ápice sobre el cual se realiza la lectura y posterior medición con el hipsómetro laser puede resultar más compleja que la lectura del DAP.

Considerando el volumen con corteza calculado sobre las parcelas inventariadas y el estimado a partir del modelo (Tabla 5), una diferencia del 6% resulta muy adecuada para los diagnósticos a escala regional.

Tabla 5. Volumen con corteza calculado en parcelas a campo (INPF) y volumen estimado por el modelo.

n parcelas INPF	85 parcelas (*)
Superficie INPF (ha)	990
Vol INPF (cc m ³)	199.283,36
Vol estimado (cc m ³)	186.869,25
Dif %	6,64

Referencias: n: número de parcelas relevadas en el Inventario de plantaciones forestales (INPF), **Vol INPF:** volumen con corteza (m³) calculado con las parcelas del (INPF). **Vol estimado:** volumen con corteza (m³) estimado con el modelo de regresión lineal. (*) Del total de parcelas inventariadas a campo, se descartaron 8 parcelas luego del proceso de análisis exploratorio de los datos.

El modelo para la estimación de altura dominante también presentó buenos ajustes con un valor de R^2 ajustado de 0,66 (Tabla 3 y Figura 6). En la revisión de bibliografía se encontraron antecedentes donde respuestas de R^2 ajustado inferiores incluso a 0,7 resultan operativas para mapear las variables dasométricas de interés (Alba *et al.*, 2017) y generar estratificaciones de la masa forestal. A mayores valores de altura dominante se identifica mayor dispersión de los datos. Considerando los datos empleados para validar el modelo se identifica un patrón de subestimación constante en relación a la recta de ajuste (1:1).

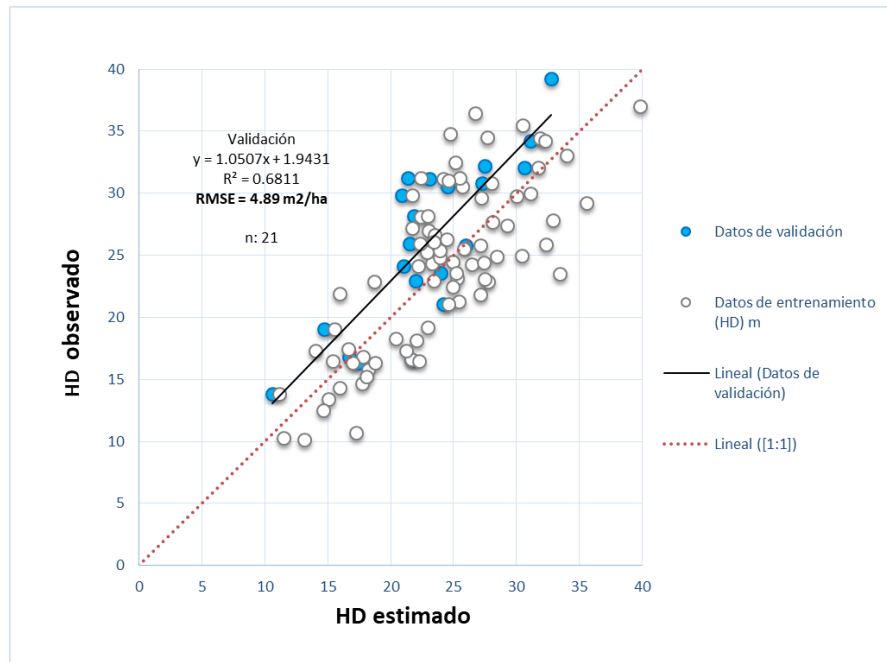


Figura 6. Gráficos de dispersión de los valores observados de altura dominante (HD) [m] versus los estimados por el modelo (HD) [m]. En línea roja se observa la recta de ajuste (1:1).

Respecto al modelo generado para estimar el índice de densidad el R^2 ajustado de 0.72 resulta alentador. El RMSE fue de 2,16; sin embargo del análisis visual del gráfico Observados vs. Predichos (Figura 7) resulta evidente la sobreestimación de los valores. Este efecto se observa independientemente del origen de los rodales (plantación, donde se desarrolla solo un fuste comercial o manejo de los rebrotes, donde se desarrollan hasta 2 fustes comerciales por cepa).




Figura 7. Índice de densidad (DR) Observado vs. Estimado. En línea roja se observa la recta de ajuste (1:1).

Los valores estimados por los distintos modelos desarrollados (área basal, volumen con corteza, altura dominante) están dentro del rango de valores esperados y obtenidos por otros autores. Sin embargo, la heterogeneidad de los rodales, producto de diferentes crecimientos asociados a distintos suelos, edades, manejos silvícolas, distribución vertical del dosel repercutió sobre la capacidad predictiva de los modelos elaborados. Este estudio se desarrolló sobre rodales, abarcando plantaciones de diferentes especies del género *Eucalyptus* (con mayor preponderancia de *Eucalyptus grandis*), estratos etarios, densidades, tipos de origen (plantación o rebrote) y manejos silvícolas aplicados (cantidad y alturas de podas, intensidad de raleos). En el caso de dos Reis *et al* 2018, el estudio fue conducido sobre 20 plantaciones clonales de *Eucalyptus urophylla* S.T.Blake x *Eucalyptus camaldulensis* Dehnh, cuya fecha de plantación fue 2004 con un espaciamiento 3 x 2 y 3 x 3 m. Esta mayor diversidad de estratos presentes en la masa forestal evaluada, pueda afectar negativamente en el rendimiento de los modelos generados incrementando los valores de RMSE en las distintas variables estudiadas. En nuestro caso encontramos mayor diferencia entre los valores mínimos y máximos registrados en las distintas variables medidas a campo comparando con los obtenidos por

dos Reis *et al.*, (2018). En el caso de Hall *et al.*, (2006) han evaluado su técnica sobre cuatro ecoregiones con bosques no implantados, donde el 78 % de ocupación correspondía a *Pinus contorta* Dougl, *Picea glauca* (Moench) Voss, *Populus basamifera* L.

Nuevos estudios efectuados sobre la base de un diseño estratificado considerando el origen de los rodales permitirá conducir mejor la investigación. Posiblemente modelos de regresión que contemplen variables categóricas (“dummy”), serán muy útiles (donde el origen de la plantación sea la categoría, aportarían mayor robustez al modelo generado) (Fassola *et al.*, 2010). Asimismo, la incorporación del uso de LIDAR aerotransportados o terrestres, permitirá vincular la información espectral y datos SAR con la de terreno a muy alta resolución espacial. Birger *et al.*, (2015) han contemplado en el análisis de validación la inclusión de la variable sitio, para describir la función de ajuste conforme los distintos tratamientos (sitios).

Si bien en esta instancia no se buscó analizar las relaciones hipsométricas entre variables, como el diámetro del fuste y la altura dominante, la disponibilidad de datos actualizados estimados a partir de múltiples sensores remotos posibilitaran ampliar los estudios y sumar otras variables como el número de individuos (densidad de la plantación) y otros índices como el Factor Altura (FH) [m/m] (Andenmatten 1999), el cual también contempla en su ecuación la relación con la densidad. Además se podrá cuantificar los cambios en las variables estimadas a través del tiempo, en función de los diferentes manejos silvícolas que se realizan sobre los cultivos.

Al considerar la cantidad de muestras que se utilizaron en el proceso de validación se debería considerar el correcto el balanceo del diseño de muestro considerando tipos de orígenes (plantación y manejo de rebrote) y estratos etarios. La generación de modelos predictivos a partir de datos espectrales podría replicarse en otras regiones del país de importancia forestal, para lo cual será muy importante contar con un diseño de muestreo a campo favoreciendo la correcta distribución y cantidad de muestras y estratos para el proceso de calibración y validación (Saarela, *et al.*, 2015; Boca, 2016).

4.2. Relación entre altura dominante HD, altura de canopeo y edad de la plantación.

En relación a la evaluación de los datos altimétricos de ICESat-2 y la altura dominante estimada (Figura 8) este primer análisis resulta auspicioso ($R^2 = 0,77$ y RMSE = 4,06 m). Hansen *et al.*, (2016) ha obtenido resultados en el orden de los 2,45 m (Error Absoluto Medio) a partir de calibraciones de datos espectrales Landsat ETM y OLI calibrados a partir de información LIDAR ICESat (Geoscience Laser Altimeter System - GLAS).

Si bien del análisis del gráfico Observado versus Predichos, se identifican efectos de sobreestimación a mayores valores de altura de canopy. (Figura 29) es importante considerar que la cantidad de puntos evaluados es baja ($n=10$) y la altura dominante corresponde a la altura de los árboles con mayor DAP a diferencia de la altura “relativa” del canopy relevada por ICESat-2 en la transecta de 100 m. Es importante considerar que en esta evaluación comparativa se estimó la altura dominante para el año correspondiente al momento de las mediciones (2016) y luego también se hizo la estimación para el año 2019 coincidente con la disponibilidad de datos ICESat-2. No se han estudiado ni cuantificados los cambios a través del tiempo para esta variable siendo objeto de estudio en etapas posteriores.

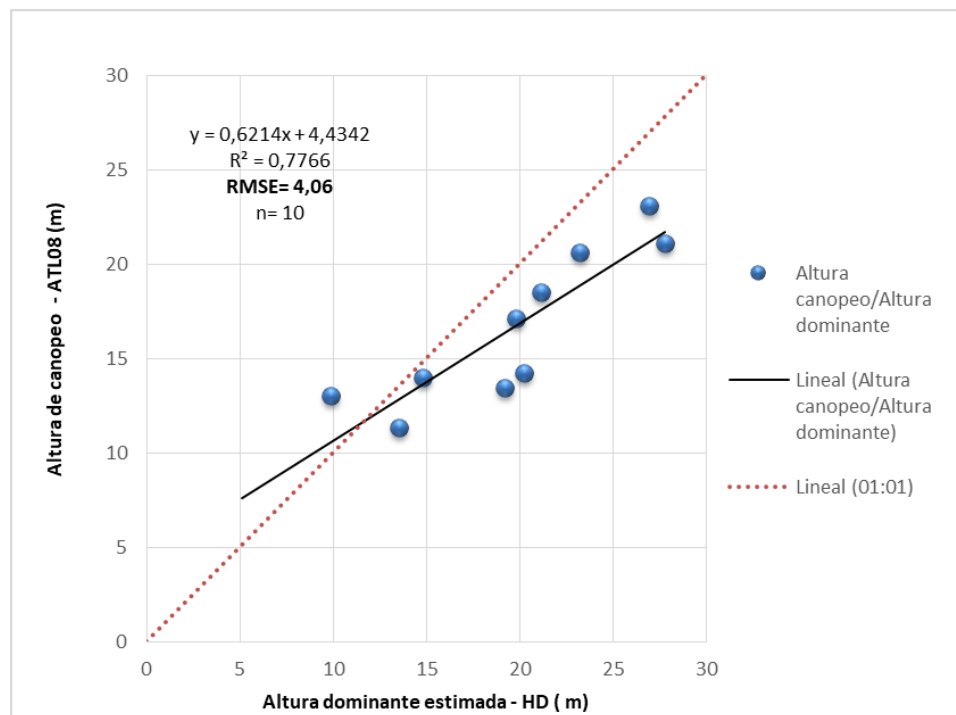


Figura 8. Relación entre altura dominante (HD) estimada con modelo para el período (noviembre – diciembre 2019) y altura de canopy relevada por ICESat- 2 (ATL08) (2019). En línea roja se observa la recta de ajuste (1:1).

La relación entre la altura dominante y la altura de canopy demostró una tendencia positiva en relación con el crecimiento de los rodales a medida que se incrementan las edades y sus correspondientes estratos etarios (recientes, juveniles y adultas) (Figura 9). Si bien son pocos los datos empleados en cada estrato etarios se observa que en el caso de las plantaciones recientes existe mayor dispersión de datos en lo que respecta a las alturas de canopy. Es necesario considerar que si bien la fecha de plantación (edad) es conceptualmente homogénea dentro del rodal sobre el cual se analizan los puntos altimétricos del sensor LIDAR, pueden existir sitios con reposiciones producto de fallas ocurridas durante las etapas tempranas de crecimiento de la

plantación. Con frecuencia se realizan para subsanar las pérdidas ocasionadas por ataques de enfermedades y plagas, eventos climáticos o limitantes edáficas; lo cual puede contribuir negativamente con el ajuste logrado. Asimismo dependiendo de la productividad del sitio, la altura puede variar dentro de un mismo estrato etario manifestando espacialmente la heterogeneidad intra rodal. Por tal motivo considerando estas limitantes, al utilizar estas herramientas sería oportuno abordar el análisis considerando rangos de alturas estimadas para los diferentes rangos de edades.

En próximas investigaciones se requiere hacer un diseño de muestreo que contemple la ubicación de las transectas de estas plataformas (ICESat o GEDI), de tal forma de establecer sobre ellas las muestras y poder relevar las variables dasométricas (Figura 3); estimando las variables con los modelos desarrollados y comparando al mismo tiempo con los datos aportados por los sensores remotos (sensores ópticos y LIDAR).

Por último este proceso resalta la capacidad la interfaz de programación de las plataformas GEE de poder configurar un período de análisis y ejecutar rápidamente el modelo sobre el área a evaluar; sin descuidar el alcance de los modelos, los cuales no deben aplicarse sobre áreas que no han sido calibradas y/o para el estudio de otras especies forestales.

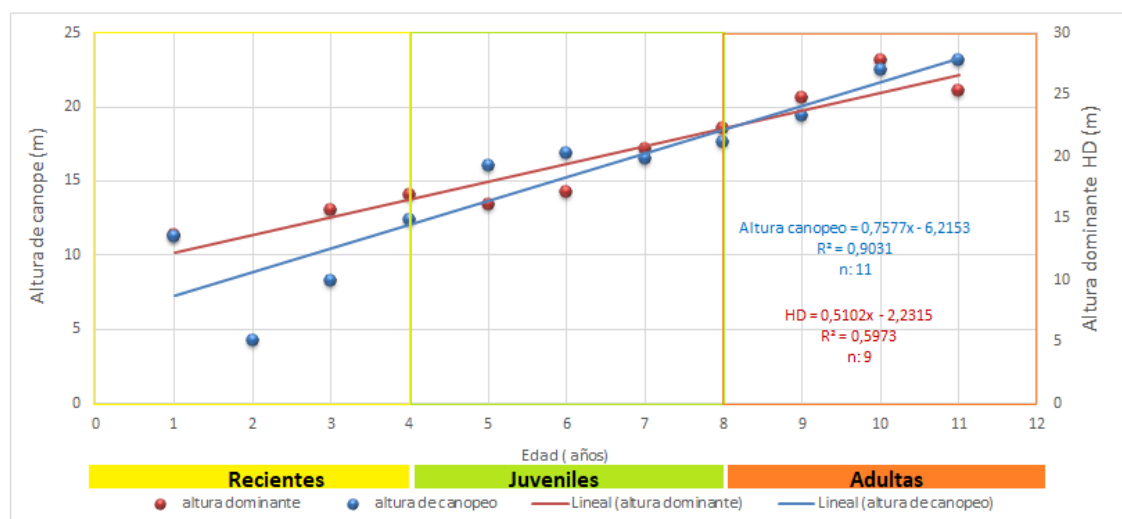


Figura 9 . Relación entre la altura de canopeo ICESat-2, altura de canopeo y edad de plantaciones. Sobre el eje x se visualizan los estratos etarios (recientes hasta 4 años, juveniles 5 a 8 o adultas mayores a 8 años).

4.3. Mapeo de las variables estimadas.

A partir de los resultados de este trabajo se realizó el mapeo donde se presentan las variables de estado estimadas a partir las herramientas disponibles en la plataforma GEE y los modelos de regresión elaborados.

(Figura 10). Asimismo se ha generado un visor web accesible desde el siguiente link:

<https://mgaute14.users.earthengine.app/view/apptfgautecaracterizacionplantacionesforestales>. (Gaute *et al.*, 2020)

La resolución de los mapas generados nos permite visualizar la heterogeneidad y distribución espacial de las variables a escala regional y de rodal, explicitando de una forma gráfica la heterogeneidad entre y dentro de los rodales. Esto favorece, en etapas previas a un inventario la posibilidad de generar estratificaciones para luego orientar la distribución de parcelas de relevamiento o calibración; disminuyendo por otra parte el número de parcelas necesarias para la caracterización, reduciendo los costos de logística asociados.

En esta investigación no se han aplicado técnicas de interpolación espaciales, como si han realizado otros autores, a pesar de que dos Reis *et al.*, (2018) no han reportado mejoras al incorporar métodos de interpolación.

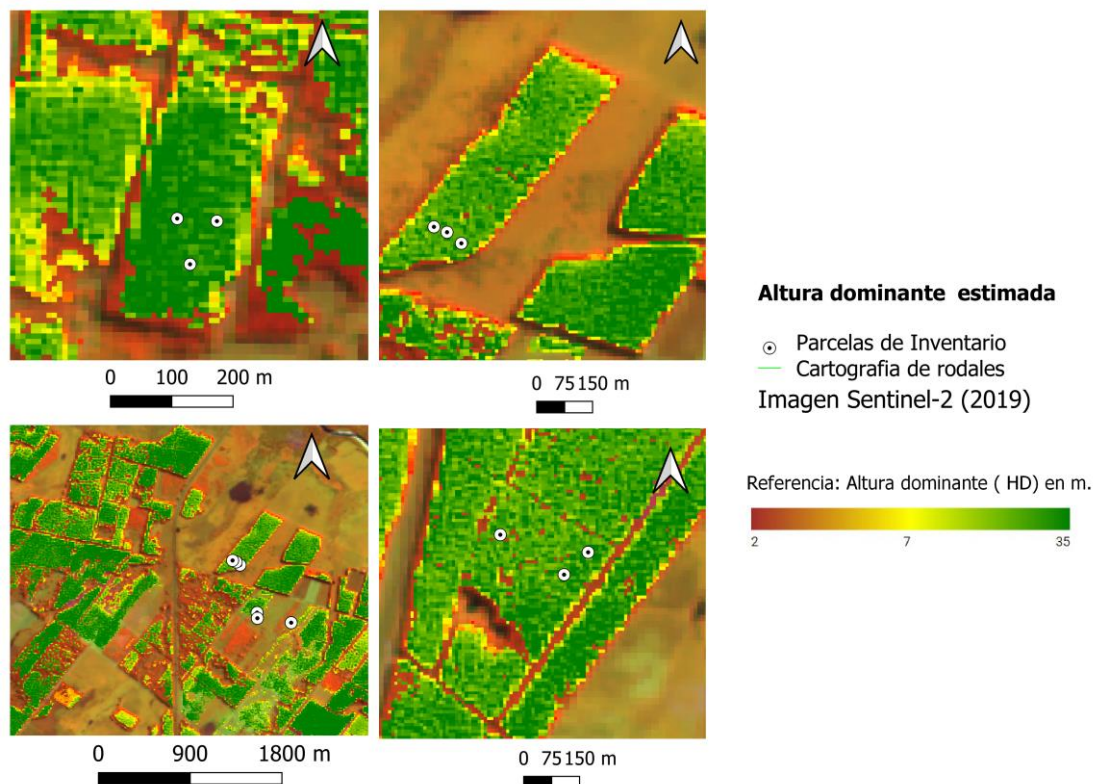


Figura 10. Mosaico correspondiente a la altura dominante (HD) estimada para el año 2019 sobre el área de estudio. La imagen de fondo corresponde Sentinel-2 de abril de 2019. RGB: bandas infrarrojo cercano - NIR (8), infrarrojo de onda corta SWIR (11), rojo (4) respectivamente. Se identifica la ubicación de parcelas relevadas a campo sobre la cartografía forestal.

5. Conclusiones

A partir de la información relevada a campo y de la provista por los sensores remotos fue posible construir modelos predictivos para estimar la distribución espacial de las variables de estado de interés forestal, en plantaciones comerciales de *Eucalyptus* en el departamento Concordia.

La información espectral del satélite Sentinel-2 resultó muy apropiada para la generación de modelos y los correspondientes mapas. La información de Sentinel-1, no fue considerada por los modelos seleccionados y en futuros estudios sería recomendable su evaluación y también la de los datos del satélite argentino SAOCOM 1a y 1b.

Considerando las variables de estado analizadas (área basal, volumen, altura dominante) el modelo predictor de área basal, mostró los valores más elevados de bondad de ajuste, aunque todos los modelos presentaron buenos ajustes.

En próximas investigaciones resulta de interés determinar los rangos para las diferentes variables en que se pueden realizar las estimaciones, sin encontrar respuestas de saturación y/o de subestimación.

La altura dominante estimada se correlacionó positivamente con la altura de canopeo relevada por el LIDAR satelital ICESat-2 reforzando la posibilidad de utilizar estas herramientas complementarias para calibrar modelos y o utilizar datos para su validación.

La relación entre la altura dominante, la altura de canopeo y la edad de los rodales demostró un patrón lógico acorde al crecimiento de las plantaciones comerciales esperado a través del tiempo. El rango de valores detectados se correspondió con distintos estratos etarios (recientes, juveniles a adultas) pero para una mejor calibración y validación de todos los modelos generados se requiere un diseño de muestreo estratificado que permita obtener suficiente cantidad de muestras tanto para la etapa de entrenamiento como la de validación de los modelos, en forma balanceada, considerando el tipo origen de las plantaciones, estratos etarios, especies y densidades.

Considerando la importancia de la dinámica en el manejo silvícola de los macizos forestales de *Eucalyptus* en esta región del país, con rápidas tasas de crecimiento, las técnicas desarrolladas y evaluadas en esta instancia, para la estimación de variables de estados forestales a partir de información proveniente de sensores remotos, favorecerán la frecuencia de datos descriptivos del recurso forestal a partir de una metodología documentada, de bajo costo, replicable en otras regiones y /o con otras especies de interés forestal (coníferas, salicáceas) principalmente, a escala regional.

Sería deseable en nuevas investigaciones complementar los modelos generados con datos provenientes de otras misiones SAR (ALOS, SAOCOM), LIDAR satelital (ICESAT - 2 y GEDI) y fotografías aéreas relevadas a partir de UAVs.

6. Referencias bibliográficas

- Ahl, D. E., Gower, S.T. Burrows, S.N., Shabanov, N. V., Myneni, R. B, Knyazikhin, Y. (2006). Monitoring spring canopy phenology of a deciduous broadleaf forest using MODIS. *Remote Sensing of Environment* 104 (2006) 88-95.
- Alba, E., Pivotto Marchesan E., Juliana, Silva J., Araújo E., Tramontina J., & Pereira, Rudiney Soares. (2017). Spectral characterization of forest plantations with Landsat 8/OLI images for forest planning and management. *Pesquisa Agropecuária Brasileira*, 52(11), 1072-1079. <https://dx.doi.org/10.1590/s0100-204x2017001100013>
- Andenmatten, E. (1999). "Proyección de Tablas de Rodal para pino Oregón en la región Andino-Patagónica, de las provincias de Chubut y Río Negro, Argentina". Tesis Maestría. Universidad Austral de Chile. Valdivia. 80 p.
- Andenmatten E., Letourneau F. J., Nicolás De Agostini N., Getar E. (2013). PILTRUITRON 1.1: Simulador para el procesamiento de parcelas forestales. Comunicación Técnica N° 52. Área Forestal Silvicultura. INTA..
- Andenmatten, Ernesto. (2017). Algoritmo para predecir mortalidad y proyectar parámetros descriptivos del rodal, basado en índices de densidad. Comunicación técnica N° 59. Área forestal silvicultura .2017.
- Andenmatten, Ernesto. (2019). Autorraleo: alternativa para determinar la pendiente de la relación lineal tamaño-densidad, mediante su impacto en la estimación del volumen del rodal. *Bosque (Valdivia)*, 40(2), 153-162. <https://dx.doi.org/10.4067/S0717-92002019000200153>.
- Assman E. (1970). The principles of forest yield study. Pergamon Press. Oxford. 506 p
- Astrup R., Rahlf J. , Bjørkelo K., Debella-Gilo M., Gjertsen A.K. & Breidenbach J.(2019) Forest information at multiple scales: development, evaluation and application of the Norwegian forest resources map SR16, *Scandinavian Journal of Forest Research*, 34:6, 484-496, DOI: 10.1080/02827581.2019.1588989
- Bagaram, M.B.; Giularelli, D.; Chirici, G.; Giannetti, F.; Barbati, A. (2018). UAV Remote Sensing for Biodiversity Monitoring: Are Forest Canopy Gaps Good Covariates? *Remote Sens.*10, 1397. <https://doi.org/10.3390/rs10091397>
- Bengoa Martínez de Mandojana J.L. (1999). Estimación de la altura dominante de la masa a partir de la altura dominante de parcela. Ventajas frente a la altura dominante de Assman. *Invest. Agr.: Sist. Recur. For.: Fuera de Serie* n° 1 - Diciembre.

- Beguet B., Guyon D., Boukir S., Chehata N. (2014). Automated retrieval of forest structure variables based on multi-scale texture analysis of VHR satellite imagery, ISPRS Journal of Photogrammetry and Remote Sensing. Volume 96, Pages 164-178.
- Birger H. (2015). Empirical models for estimating volume and biomass of poplars on farmland in Sweden. Diss. (sammanfattning/summary) Uppsala : Sveriges lantbruksuniv., Acta Universitatis Agriculturae Sueciae, 1652-6880 ; 2015:1, ISBN 978-91-576-8200-0, eISBN 978-91-576-8201-7.
- Boca T. (2016). Workshop. Accuracy assessment of thematic maps. Santa Martha, Colombia. Octubre 3-7.
- Canty, M. J., Nielsen, A. A., Conradsen, K., & Skriver, H. (2019). Statistical Analysis of Changes in Sentinel-1 Time Series on the Google Earth Engine. Remote Sensing, 12(1), [46]. <https://doi.org/10.3390/rs12010046>.
- Crechi, E. H.; Fassola, H. E.; Keller, A. E. & Barth, S. R. (2011). Desarrollo de funciones de índice de sitio para *Eucalyptus grandis* cultivado en la Mesopotamia Argentina. RIA, Vol. 37, No. 3. pp. 238 – 248. [fecha de Consulta 10 de octubre de 2020]. ISSN: 0325-8718. Disponible en: <https://www.redalyc.org/articulo.oa?id=864/86421245008>
- Chen, L., Wang, Y., Ren, C., Zhang, B., & Wang, Z. (2019). Optimal Combination of Predictors and Algorithms for Forest Above-Ground Biomass Mapping from Sentinel and SRTM Data. Remote Sensing, 11(4), 414. doi:10.3390/rs11040414.
- Dalla Corte, A.P.; Rex, F.E.; Almeida, D.R.A.; Sanquetta, C.R.; Silva, C.A.; Moura, M.M.; Wilkinson, B.; Zambrano, A.M.A.; Cunha Neto, E.M.; Veras, H.F.P.; Moraes, A.; Klauberg, C.; Mohan, M.; Cardil, A.; Broadbent, E.N. (2020) . Measuring Individual Tree Diameter and Height Using GatorEye High-Density UAV-Lidar in an Integrated Crop-Livestock-Forest System. Remote Sens. 2020 12, 863. <https://doi.org/10.3390/rs12050863>
- de Abelleira D, Gaute MC, Verón S, Benítez R (2013). Caracterización de bosques cultivados de la Mesopotamia argentina a partir de imágenes de RADAR de diferentes frecuencias y polarizaciones. 4º Congreso Forestal Argentino y Latinoamericano. 23 al 27 de septiembre de 2013. Iguazú, Argentina.
- developers.google.com. (2020). https://developers.google.com/earth-engine/datasets/catalog/COPERNICUS_S1_GRD [Última consulta: 17 Noviembre de 2020].
- De Zan, F. y Guarnieri, AM (2006). TOPSAR: Observación del terreno mediante escaneos progresivos. Geociencia y Teledetección, IEEE Transactions on, 44 (9), 2352-2360. doi: 10.1109 / TGRS.2006.873853

- Di Rienzo JA, F Casanoves, MG Balzarini, L Gonzalez, M Tablada, CW Robledo. (2013). InfoStat versión 2013. Grupo InfoStat, FCA, Universidad Nacional de Córdoba, Argentina. <http://www.infostat.com.ar/>
- dos Reis A. A. , Carvalho M.C. ,de Mello J. M., Rezende Gomide L., Ferraz Filho A. , Acerbi Junior W. (2018). Spatial prediction of basal area and volume in *Eucalyptus* stands using Landsat TM data: an assessment of prediction methods. New Zealand Journal of Forestry Science (2018) 48:1 DOI 10.1186/s40490-017-0108-0
- ESA Sentinel 1.(2020). <https://sentinel.esa.int/web/sentinel/missions/sentinel-1/instrument-payload>
- ESA. Sentinel–2. (2020). MSI. <https://sentinel.esa.int/web/sentinel/user-guides/sentinel-2-msi/overview> [Última consulta: 22 Noviembre de 2020].
- ESA.(2015). SENTINEL-2 User Handbook. [https://sentinel.esa.int/documents/247904/685211/Sentinel-2 User Handbook](https://sentinel.esa.int/documents/247904/685211/Sentinel-2_User_Handbook) [Última consulta: 22 Noviembre de 2020].
- Fagua, J.C.; Jantz, P.; Rodriguez-Buritica, S.; Duncanson, L.; Goetz, S.J. (2019). Integrating LIDAR, Multispectral and SAR Data to Estimate and Map Canopy Height in Tropical Forests. Remote Sens, 11, 2697.
- Fassola, H. E.1 ; Crechi, E. H.1 ; Barth, S. R. 1; Keller, A.E. 1; Winck, R. A. 1; Martiarena, R. 1; Von Wallis, A. 1, Pinazo, M. A.1 ; Knebel, O. 1 (2010). Modelos Regionales de Biomasa Aerea de Pinus taeda para Misiones y NE de Corrientes, Argentina. https://inta.gob.ar/sites/default/files/script-tmp-modelos_biomasa_aerea_pinus.pdf
- Fassola, H.; Crechi, E.; Keller, A.; Barth, S. & Costa, J. (2007). Funciones de volumen total para *Eucalyptus grandis* Hill ex Maiden implantado en el NE de la provincia de Entre Ríos, Argentina. 12as Jornadas Técnicas Forestales y Ambientales – FCF, UNaM – EEA Montecarlo, INTA.
- Fassola, H.E.; Crechi, E.; Keller, A. & Barth, S. (2007). Funciones de forma de exponente variable para la estimación de diámetros a distintas alturas en *Eucalyptus grandis* Hill ex Maiden. Cultivado en la Mesopotamia Argentina. RIA, 36 (2): 109-128. Agosto 2007. INTA, Argentina.
- Gärtner. (2019). Checking Earth Engine's Sentinel-2 Surface Reflectance ingestion status. <https://philippgaertner.github.io/2019/04/gee-s2-level-2a-ingestion/>.
- Gärtner.(2019). NEW!! Earth Engine App Gallery. <https://philippgaertner.github.io/2019/07/earth-engine-apps-gallery/>

- Gaute M., Sione W. (2020) Caracterización de plantaciones forestales a partir de información derivada de plataformas satelitales y servicios de procesamiento de datos en la nube. <https://mgaute14.users.earthengine.app/view/apptfgautecaracterizacionplantacionesforestales>
- Gebreslasie MT, Ahmed, FB, Aardt, JAN. (2010). Predicting forest structural attributes using ancillary data and ASTER satellite data. International Journal of Applied Earth Observation and Geoinformation, 12S, S23–S26. <https://doi.org/10.1016/j.jag.2009.11.006>.
- gee-community. (2020). Integrates Google Earth Engine and QGIS using Python API <https://gee-community.github.io/qgis-earthengine-plugin/>
- Gemmell, F.M. (1995). Effects of forest cover, terrain, and scale on timber volume estimation with Thematic Mapper data in the rocky mountain site. Rem. Sens. Environ. 51, 291–305. [https://doi.org/10.1016/0034-4257\(94\)00056-S](https://doi.org/10.1016/0034-4257(94)00056-S).
- Ghasemi N, Sahebi M.R., Mohammadzadeh A. (2011) .A review on biomass estimation methods using synthetic aperture radar data. International Journal of Geomatics and Geosciences . Volume 1, No 4. ISSN 0976 – 4380. <http://ipublishing.co.in/jggsvol1no12010/EIJGGS2038.pdf>
- Gómez-Tejero, Joaquín, De los Santos-Posadas, Héctor M., Fierros-González, Aurelio M., & Valdez-Lazalde, J. René. (2009). Modelos de crecimiento en altura dominante para *Eucalyptus grandis* Hill ex Maiden y *E. urophylla* S. T. Blake en Oaxaca, México. Revista fitotecnia mexicana, 32(2), 161-169. Recuperado en 09 de diciembre de 2020, de http://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0187-73802009000200012&lng=es&tlng=es.
- Google Earth Engine , <https://earthengine.google.com/>
- Gorelick, N.; Hancher, M.; Dixon, M.; Ilyushchenko, S.; Thau, D.; R. Moore .(2017) .Google Earth Engine: Planetary-scale geospatial analysis for everyone. <http://www.sciencedirect.com/science/article/pii/S0034425717302900#!> <https://doi.org/10.1016/j.rse.2017.06.031>
- Guillón L., Maradei D., (1988). Procesamiento automático en imágenes satelitarias en Planificación Forestal. Artículo entregado para la publicación.
- H. Nguyen, T.; Jones, S.; Soto-Berelov, M.; Haywood, A.; Hislop, S. (2020) Landsat Time-Series for Estimating Forest Aboveground Biomass and Its Dynamics across Space and Time: A Review. Remote Sens. 2020, 12, 98. <https://doi.org/10.3390/rs12010098>

- Hall, F., Shimabukuro, Y., & Huemmrich, K. (1995). Remote Sensing of Forest Biophysical Structure Using Mixture Decomposition and Geometric Reflectance Models. *Ecological Applications*, 5(4), 993-1013. doi:10.2307/2269350.
- Hall R.J., Skakun R.S., Arsenault E.J., Case B.S. (2006). Modeling forest stand structure attributes using Landsat ETM+ data: Application to mapping of aboveground biomass and stand volume. *Forest Ecology and Management* 225: 378–390.
- Hansen M. C., Potapov P. V., Moore R., Hancher M., Turubanova S. A., Tyukavina A. Thau D. , Stehman S. V. , Goetz S. J. , Loveland T. R., Kommareddy A. , Egorov A. , Chini L., Justice C. O., Townshend J. R. G. (2013). High-Resolution Global Maps of 21st-Century Forest Cover Change. *Science* 15 Vol. 342, Issue 6160, pp. 850-853 DOI: 10.1126/science.1244693
- Hansen M.C., Potapov P.V., Goetz S.J., Turubanova S., Tyukavina A., Krylov A. , Kommareddy A. , Egorov A. (2016). Mapping tree height distributions in Sub-Saharan Africa using Landsat 7 and 8 data. *Remote Sensing of Environment*. Volume 185..Pages 221-232.ISSN 0034-4257. <https://doi.org/10.1016/j.rse.2016.02.023>
- Hibberd, B.G. (Ed). (1991). *Forestry Practice*. Forestry Commission Handbook 6. London. HMSO. ISBN 0-11-710281-4. https://sentinel.esa.int/documents/247904/685211/Sentinel-2_User_Handbook
- Huang S, Y Yang, Y Wang. (2003). Critical Look at Procedure for Validating Growth and Yield Models. In Amaro A, D Reed, P Soares eds. *Modelling Forest Systems*. CAB International. 23 p. https://link.springer.com/chapter/10.1007/3-540-31304-4_12
- Huete, A, Didan, K, Miura, T, Rodriguez, EP, Gao, X, Ferreira, LG. (2002). Overview of the radiometric and biophysical performance of the MODIS vegetation indices. *Remote Sensing of Environment*, 83, 195–213. [https://doi.org/10.1016/S0034-4257\(02\)00096-2](https://doi.org/10.1016/S0034-4257(02)00096-2).
- Huete, AR. 1988. A soil-adjusted vegetation index (SAVI). (2014). *Remote Sensing of Environment*, 25, 295–309. [https://doi.org/10.1016/0034-4257\(88\)90106-X](https://doi.org/10.1016/0034-4257(88)90106-X).ISSN 0924-2716, <https://doi.org/10.1016/j.isprsjprs..07.008>
- ICESat-2.ATL08. NSIDC. The National Snow and Ice Data Center (NSIDC). <https://nsidc.org/about/overview>
- INPF. (2017): Inventario Nacional de Plantaciones Forestales. Entre Ríos - Área Continental. Ministerio de Agroindustria, Diciembre 2017. https://www.agroindustria.gob.ar/sitio/areas/ss_desarrollo_foresto_industrial/censos_inventario/archivos/inventario/000000_Inventario%20Entre%20R

[%C3%ADos%20-%20%C3%81rea%20continental.pdf](#) [Última consulta: Noviembre de 2020].

JAXA. 2019. https://www.eorc.jaxa.jp/ALOS/en/palsar_fnf/fnf_index.htm [Última consulta: 12 de Octubre de 2019].

Kangas, A, Astrup, R, Breidenbach, J, Fridman, J, Gobakken, T, Korhonen, KT, Maltamo, M, Nilsson, M, Nord-Larsen, T, Næsset, E & Olsson, H (2018). Remote sensing and forest inventories in Nordic countries - roadmap for the future. *Scandinavian Journal of Forest Research*, vol. 33, no. 4, pp. 397-412. <https://doi.org/10.1080/02827581.2017.1416666>.

Kennedy, R.E., Yang, Z., Gorelick, N., Braaten, J., Cavalcante, L., Cohen, W.B., Healey, S. (2018). Implementation of the LandTrendr Algorithm on Google Earth Engine. *Remote Sensing*. 10, 691.

Lu D., Mausel P., Brondízio E., Moran E. (2004). Relationships between forest stand parameters and Landsat TM spectral responses in the Brazilian Amazon Basin, *Forest Ecology and Management*, Volume 198, Issues 1–3, Pages 149-167, ISSN 0378-1127, <https://doi.org/10.1016/j.foreco.2004.03.048>. (<http://www.sciencedirect.com/science/article/pii/S0378112704003445>)

Maggio A. Cellini J. M., (2016). Recopilación de ecuaciones de volumen y biomasa de especies forestales de la República Argentina. Publicación del Ministerio de Ambiente y Desarrollo Sustentable de la Presidencia de la Nación Argentina. <http://sedici.unlp.edu.ar/handle/10915/54918>

Mohammadi J., Shaban Shataee S. (2010). Estimation of Forest stands Volume and Tree density using ETM+ and ancillary data. *Procedia Environmental Sciences*. Elsevier. Volume 7, Pages 299-304. <https://doi.org/10.1080/01431160903140811>

Narine, L.L.; Popescu, S.C.; Malambo, L. (2019). Synergy of ICESat-2 and Landsat for Mapping Forest Aboveground Biomass with Deep Learning. *Remote Sens.* 2019, 11, 1503.

Neuenschwander, A. L., S. C. Popescu, R. F. Nelson, D. Harding, K. L. Pitts, and J. Robbins. (2019). ATLAS/ICESat-2 L3A Land and Vegetation Height, Version 1. [Indicate subset used]. Boulder, Colorado USA. NSIDC: National Snow and Ice Data Center. doi: <https://doi.org/10.5067/ATLAS/ATL08.001>. [Date Accessed].

Neuenschwander, A.L.; Magruder, L.A. (2019). Canopy and Terrain Height Retrievals with ICESat-2: A First Look. *Remote Sens.* , 11, 1721.

Open Foris.(2019). <https://github.com/openforis/sepal/wiki>.

OpenStreetMap. 2020. <https://www.openstreetmap.org>.

Piñeiro G., Perelman S., Guerschman J.P., Paruelo JM. (2008). How to evaluate models: Observed vs. predicted or predicted vs. observed?. *Ecological Modelling*. Volume 216, Issues 3–4, 2008. Pages 316-322, ISSN 0304-3800, <https://doi.org/10.1016/j.ecolmodel.2008.05.006>.

Ponzoni, FJ, Shimabukuro, YE, Kuplich, TM (2012). *Sensoriamento Remoto da Vegetação*, (2nd ed.,). São Paulo: Oficina de Textos.

Ponzoni, FJ, Pacheco, LRF, Santos, SB, Andrades Filho, CO. (2015). Caracterização espectro-temporal de dosséis de *Eucalyptus* spp. mediante dados radiométricos TM/Landsat 5. *Cerne*, 21(2), 267–275. <https://doi.org/10.1590/01047760201521021457>.

Pourshamsi, M., Garcia, M., Laval, M., & Balzter, H. (2018). A machine-learning approach to PolInSAR and LiDAR data fusion for improved tropical forest canopy height estimation using NASA AfriSAR Campaign data. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 11 (10), 3453-3463. doi: 10.1109/JSTARS.2018.2868119

Prodan M., Peters R., Cox F., Real P. (1997). “Mensura forestal”. Ed. IICA, 586 p.

Qi W., Saarela S., Armsto J., Ståhl G., Dubayah R. (2019). Forest biomass estimation over three distinct forest types using TanDEM-X InSAR data and simulated GEDI lidar data. *Remote Sensing of Environment*. Volume 232..111283. ISSN 0034-4257. <https://doi.org/10.1016/j.rse.2019.111283>

Rejou-Mechain M, Tanguy A, Piponiot C, Chave J, Herault B (2017). “BIOMASS : an R package for estimating above-ground biomass and its uncertainty in tropical forests.” *Methods in Ecology and Evolution*, 8(9). ISSN 2041210X, doi: 10.1111/2041-210X.12753, <http://doi.wiley.com/10.1111/2041-210X.12753>.

Rouse, J, Haas, R, Schell, J, Deering, D, Harlan, J (1973). Monitoring the vernal advancements and retrogradation (greenwave effect) of nature vegetation. NASA/GSFC final report. Greenbelt: NASA.

Roussel, J. R., Auty, D., De Boissieu, F., & Meador, A. S. (2018). lidR: Airborne LiDAR data manipulation and visualization for forestry applications. R package version, 1(1).

RStudio Team (2020). RStudio: Integrated Development for R. RStudio, PBC, Boston, MA URL <http://www.rstudio.com/>.

Saarela S., Grafström A., Ståhl G., Kangas A., Holopainen M. , Tuominen S. , Nordkvist K. , Hyypä J. (2015). Model-assisted estimation of growing stock

- volume using different combinations of LiDAR and Landsat data as auxiliary information. *Remote Sensing of Environment*. Volume 158..Pages 431-440.ISSN 0034-4257. <https://doi.org/10.1016/j.rse.2014.11.020>
- Sen2Cor. <http://step.esa.int/main/third-party-plugins-2/sen2cor/> [Última consulta: 28 de Noviembre de 2020].
- Schumacher, J.; Rattay, M.; Kirchhöfer, M.; Adler, P.; Kändler, G. (2019). Combination of Multi-Temporal Sentinel 2 Images and Aerial Image Based Canopy Height Models for Timber Volume Modelling. *Forests* 2019, 10, 746.
- Sivanpillai R., Smith C.T., Srinivasan R., Messina M.G., Wu X.B (2006). Estimation of managed loblolly pine stand age and density with Landsat ETM+ data. *Forest Ecology and Management*. Volume 223, Issues 1–3. Pages 247-254. ISSN 0378-1127. <https://doi.org/10.1016/j.foreco.2005.11.013>.
- Tang H., Armston J., Hancock S., Marselis S., Goetz S., Dubayah R. (2019). Characterizing global forest canopy cover distribution using spaceborne lidar. *Remote Sensing of Environment*. Volume 231. 2019.111262. ISSN 0034-4257. <https://doi.org/10.1016/j.rse.2019.111262>. (<http://www.sciencedirect.com/science/article/pii/S0034425719302810>).
- Team, R. C. (2017). R Foundation for Statistical Computing; Vienna, Austria: 2016. R: A language and environment for statistical computing. URL <http://www.R-project.org/>
- Thomas O., Stallings C., Wilkinson B.E. (2018). *Journal of Unmanned Vehicle Systems*, 0, 0, <https://doi.org/10.1139/juvs-2018-0030>.
- Torres- Rojas G., Romero- Sanchez, M. E., Velasco- Bautista E. y Gonzalez – Hernandez A. (2016). Estimación de parámetros forestales en bosques de coníferas con técnicas de percepción remota. *Rev. mex. de cienc. forestales* [online]. vol.7, n.36 [citado 2018-12-14], pp.7-24. ISSN 2007-1132. Recuperado en 10 de diciembre de 2020, de http://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S2007-11322016000400007&lng=es&tlng=es.
- Trends.Earth. (2018). Conservation International. Available online at: <http://trends.earth>.
- Unger D.R., I-Kuai Hung I, Brooks R. , Williams H. (2014) Estimating number of trees, tree height and crown width using LIDAR data, *GIScience & Remote Sensing*, 51:3, 227-238, DOI: 10.1080/15481603.2014.909107
- Urbazaev M., Thiel C. ,Migliavacca M. , Reichstein M.,Rodriguez-Veiga P and Schmulilius C. (2016). Improved Multi-Sensor Satellite-Based Aboveground

Biomass Estimation by Selecting Temporally Stable Forest Inventory Plots Using NDVI Time Series. *Forests* 2016, 7(8), 169, doi:10.3390/f708016

- Vanclay JK. (1994). *Modelling Forest Growth and Yield-Application to Mixed Tropical Forests*. Wallingford, UK. CAB International. 312 p. https://epubs.scu.edu.au/cgi/viewcontent.cgi?referer=https://www.google.com/&httpsredir=1&article=1538&context=esm_pubs
- Watt M.S., Dash J.P., Bhandari S., Watt P. (2015). Comparing parametric and non-parametric methods of predicting Site Index for radiata pine using combinations of data derived from environmental surfaces, satellite imagery and airborne laser scanning. *Forest Ecology and Management*. Volume 357.. Pages 1-9. ISSN 0378-1127. <https://www.sciencedirect.com/science/article/abs/pii/S037811271500417X?via%3Dihub>.
- Woodcock, C.E.; Allen, R.; Anderson, M.; Belward, A.; Bindschadler, R.; Cohen, W.; Gao, F.; Goward, S.N.; Helder, D.; Helmer, E. (2008). Free access to Landsat imagery. *Science* 23 May 2008:Vol. 320, Issue 5879, pp. 1011. DOI: 10.1126/science.320.5879.1011a
- Zhao, P.; Lu, D.; Wang, G.; Wu, C.; Huang, Y.; Yu, S. (2016) Examining Spectral Reflectance Saturation in Landsat Imagery and Corresponding Solutions to Improve Forest Aboveground Biomass Estimation. *Remote Sens.* 2016, 8, 469. <https://doi.org/10.3390/rs8060469>